

POLITECHNIKA WROCŁAWSKA
WYDZIAŁ ELEKTRONIKI

KIERUNEK: Elektronika

SPECJALNOŚĆ: Aparatura Elektroniczna

PRACA DYPLOMOWA
MAGISTERSKA

Analizator struktury snu

The Analyser of Sleep Architecture

autor : KAROL PIOTR KOLAŃSKI

Opiekun pracy:
Dr hab. inż. Adam Polak, prof. PWr
Katedra Metrologii Elektronicznej
i Fotonicznej (W4/K1)

OCENA PRACY:

Spis treści

Wstęp.....	4
1.1. Wprowadzenie	4
1.2. Cel pracy	4
1.3. Zakres pracy	5
Rozdział 1: Analiza snu na podstawie polisomnografii	6
1.1. Elektroencefalografia	7
1.2. Struktura snu	8
1.2.1. Faza czuwania	8
1.2.2. Faza NREM1	9
1.2.3. Faza NREM2	9
1.2.4. Faza NREM3 – sen głęboki	9
1.2.4. Faza REM – sen paradoksalny	10
1.3. Monitorowanie oddechu	10
Rozdział 2: Automatyczna analiza faz snu na podstawie sygnału EEG	11
2.1. Zastosowana metodyka	11
2.2. Dyskretna transformacja falkowa	11
2.3. Sztuczne sieci neuronowe	14
Rozdział 3: Projekt mikroprocesorowego systemu pomiarowego	15
3.1. Założenia projektowe	15
3.1.1. Założenia funkcjonalne	15
3.1.2. Założenia konstrukcyjne	15
3.1.3. Założenia programistyczne	16
3.2. Moduł EEG	17
3.2.1. Układ zabezpieczająco-filtrujący	17
3.2.2 Wzmacniacz instrumentalny	19

3.2.3 Układ sztucznej masy DRL	20
3.2.4 Wzmacniacz właściwy	20
3.2.5. Układ filtrująco-wzmacniający	21
3.2.6. Moduł oddechowy	22
3.3. Symulacje analogowej części systemu	22
3.3.1 Układ zabezpieczająco-filtrujący	23
3.3.2. Wzmacniacz instrumentalny	24
3.3.3. Wzmacniacz właściwy	25
3.3.4 Układ filtrująco-wzmacniający	27
3.3.5. Symulacja pełnego toru akwizycji sygnału EEG	29
3.3.6. Symulacja układu wzmacniająco-filtrującego modułu oddechowego	30
3.4. Filtr zasilania	32
3.5. Moduł mikrokontrolera	32
3.6. Wtórnik napięcia referencyjnego sygnału EEG	33
3.7. Kalibrator wzmocnienia	34
3.8. Izolowany moduł komunikacyjny	35
3.9. Karta microSD	35
Rozdział 4: Realizacja modelu urządzenia	37
4.1. Projekt urządzenia	37
4.1.1. Prototyp urządzenia EEG	37
4.1.2. Prototyp modułu oddechowego	37
4.2. Projekt i wykonanie płytek PCB w technologii SMT	38
4.3. Oprogramowanie układu	40
4.4. Testy gotowego urządzenia	41
4.4.1. Test modułu EEG	41
4.4.2. Test modułu oddechowego	42
4.5. Akwizycja sygnału EEG	43

Rozdział 5: Analiza struktury snu	50
5.1. Import wzorcowych danych z bazy PhysioNet	50
5.2. Implementacja metody ekstrakcji cech	50
5.3. Implementacja metody klasyfikacji	51
5.3.1. Wybór metody klasyfikacji	51
5.3.2. Wybór optymalnej struktury sieci neuronowej	53
5.3.3. Testy kompletnego algorytmu na danych wzorcowych	54
5.3.4. Przygotowanie danych własnych	56
5.3.5. Testy kompletnego algorytmu na danych własnych	58
5.3.6. Hipnogram dokonanego zapisu snu	59
Rozdział 6: Propozycja algorytmu detekcji bezdechu	61
6.1. Tło algorytmu	61
6.2. Opis algorytmu	61
6.3. Implementacja algorytmu	61
6.4. Test algorytmu	63
Podsumowanie i wnioski	65
Bibliografia	67

Wstęp

1.1. Wprowadzenie

Sen należy do podstawowych potrzeb człowieka. Jego brak lub niedostateczna jakość wpływają destrukcyjnie na zdrowie oraz ogólną jakość życia. Dzień, który następuje po nieprzespanej nocy, staje się uciążliwy, niezależnie od przyczyn, które do niego doprowadziły. Zmęczenie, senność oraz pogorszenie koncentracji to tylko niektóre z efektów deprywacji snu. W jej wyniku może dojść do zaśnięcia w szkole lub w pracy, a także za kierownicą samochodu. W sposób niebezpośredni dotyka to nie tylko niewyspanej osoby, ale może oddziaływać negatywnie na całe społeczeństwo.

Szacuje się, że około 30% populacji cierpi na jakąś formę zaburzenia snu. Do najczęstszych z nich należy bezsenność oraz bezdech senny [1]. W celu oceny, jak dana osoba śpi, wykonuje się badanie polisomnograficzne. Polega ono na zapisie czynności elektrycznej mózgu, pracy mięśni, ruchu gałek ocznych oraz zapisu czynności oddechowej. Takie badanie wymaga wizyty w centrum medycznym [2]. Częściej wykonuje się jego uproszczoną wersję, czyli poligrafie snu. Jest to metoda pomocna w diagnozowaniu bezdechu sennego.

Mamy tutaj do czynienia z paradoksem - z jednej strony zaburzenia snu dotyczą bardzo wielu ludzi, a z drugiej ich diagnozowanie jest utrudnione. Motywacją do stworzenia niniejszej pracy jest zaprojektowanie systemu, który mógłby być dostępny dla każdego zainteresowanego analizą snu.

1.2. Cel pracy

Celem pracy jest opracowanie prostego systemu polisomnograficznego. Składa się on z urządzenia do akwizycji dwukanałowego sygnału EEG oraz sygnału oddechowego z termistora. Aspekt badawczy pracy polega na analizie sygnału EEG pod kątem faz snu oraz na opracowaniu algorytmu wykrywania bezdechu sennego w zapisie sygnału oddechowego.

1.3. Zakres pracy

Zadania, jakie zostały zrealizowane podczas realizacji pracy dyplomowej, to:

- zapoznanie się z literaturą tematu,
- pozyskanie wzorcowych danych EEG oraz oddechowych pochodzących z bazy *PhysioNet*,
- ekstrakcja cech sygnału EEG przy użyciu algorytmu DWT,
- zaimplementowanie sieci neuronowej klasyfikującej fazy snu,
- test proponowanej sieci neuronowej na danych wzorcowych,
- projekt urządzenia do akwizycji sygnału EEG oraz oddechowego na bazie projektów *OpenEEG* oraz *Thermistor Respiratory Monitor*,
- projekt i fizyczne wykonanie płytek PCB,
- montaż urządzenia,
- dostosowanie jego oprogramowania,
- akwizycja danych sygnału EEG przy użyciu skonstruowanego urządzenia,
- test proponowanej sieci neuronowej na zarejestrowanych danych,
- zaprojektowanie algorytmu wykrywania bezdechu w sygnale oddechowym.

Rozdział 1: Analiza snu na podstawie polisomnografii

W celu wykrywania zaburzeń snu stosuje się zaawansowaną metodę diagnostyczną, określaną mianem polisomnografii (PSG). Jest to narzędzie medyczne, które polega na rejestracji kilku parametrów fizjologicznych w trakcie snu. Poza zapisem EEG stosuje się również: elektrookulografię (EOG), elektromiografię (EMG), pomiar temperatury ciała, a także rejestrację sygnałów oddechu. Badanie polisomnograficzne, dzięki swojej kompleksowości, jest skuteczniejsze w wykrywaniu szerszego spektrum zaburzeń snu.

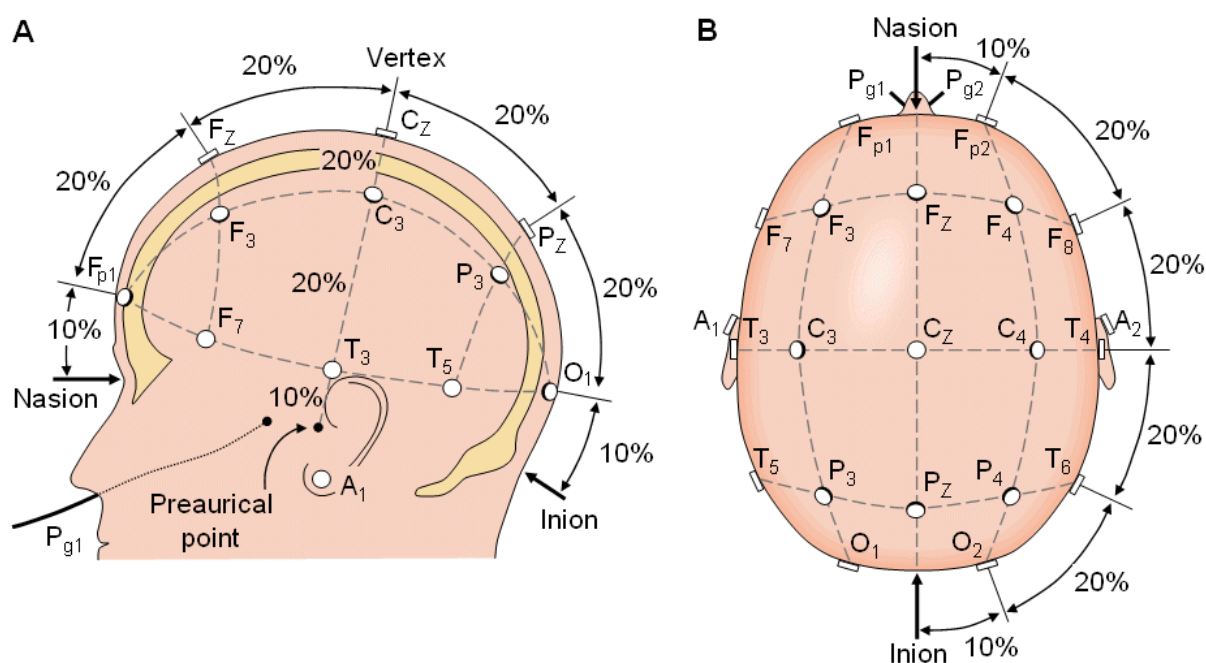
Jednym z poważniejszych, ale rzadko wykrywanych zaburzeń jest zespół bezdechu sennego OSAS (*Obstructive Sleep Apnea Syndrome*). Cierpi na niego 9% kobiet oraz 24% mężczyzn [3]. Jest to zaburzenie oddychania, które prowadzi do pogorszenia saturacji tlenu we krwi. Pacjenci dotknięci tym schorzeniem mają zwiększone szanse na śmierć w wyniku powikłań sercowo-naczyniowych o 256% [4]. Pomimo tego, większość osób dotkniętych tym schorzeniem, nie jest świadoma, że na nie cierpi. Diagnostyka wymaga przeprowadzenia kosztownego badania polisomnograficznego.



Rysunek 1.1- Pacjent poddany badaniu polisomnograficznemu[5]

1.1. Elektroencefalografia

Jednym z elementów polisomnografii jest elektroencefalografia - metoda diagnostyczna polegająca na rejestrowaniu aktywności ludzkiego mózgu przy pomocy urządzenia zwanego elektroencefalografem. Procedura ta znajduje szerokie zastosowanie w diagnozowaniu zaburzeń funkcjonowania organizmu, w tym zaburzeń snu [6]. Badanie to polega na przytwierdzeniu do skóry głowy pacjenta elektrod, które rejestrują powstające różnice potencjałów elektrycznych. Do najpopularniejszych systemów ich rozmieszczenia należy międzynarodowy układ 10-20. Pomiary czynności elektrycznej mózgu wykonuje się w tym układzie przy pomocy elektrod rozmieszczonych w określonych punktach.



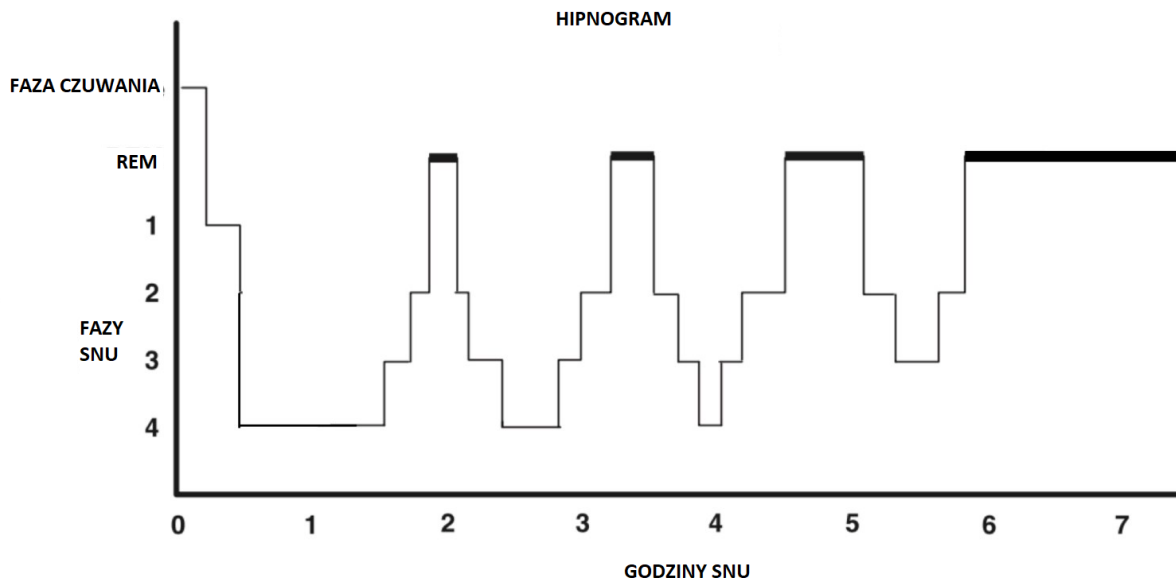
Rysunek 1.2 - Rozmieszczenie elektrod w systemie 10-20 widziane z boku (A) i góry głowy (B) [7]

Sygnały rejestrowane przy pomocy aparatury EEG określa się mianem fal mózgowych. Wyróżnia się następujące ich rodzaje: fale alfa (8-13 Hz), beta (12-28 Hz), gamma (3- do ok. 70 Hz), delta (0,5 – 3 Hz) oraz theta (4- 7 Hz).

Wynalezienie elektroencefalografii przyczyniło się do rozwoju badań nad snem. Dzięki analizie zapisów EEG odkryto fazy snu, wśród których wyróżnia się fazę snu paradoksalnego REM (*Rapid Eye Movement*) oraz sen wolnofalowy NREM (*Non-rapid Eye Movement*). Faza NREM dzieli się na 4 stadia odpowiadające głębokości snu [8]. Etapy te charakteryzują się różnym udziałem poszczególnych fal mózgowych.

1.2. Struktura snu

Struktura snu jest to wzorzec następujących po sobie faz, które przechodzimy w ciągu doby. Zmiany prawidłowego cyklu mogą być spowodowane wiekiem, stanem zdrowia czy stanem psychicznym. Przykładowy hipnogram przedstawiający stadia snu jest przedstawiony na rysunku poniżej.



Rysunek 1.3 - Hipnogram przedstawiający stadia snu [9]

1.2.1. Faza czuwania


Faza czuwania – występuje przez okres ok. 2/3 doby. W jej trakcie aktywność mięśniowa oraz kognitywna jest wysoka. Zapis EEG przedstawia fale o wysokiej częstotliwości i różnych amplitudach. Podczas odpoczynku przy zamkniętych oczach, rejestrowane są fale alfa [10].



Rysunek 1.4- Stan czuwania. Fale o niskiej amplitudzie, wysokiej częstotliwości [11]

1.2.2. Faza NREM1


Faza NREM1 u zdrowych ludzi występuje przez okres ok. 5-10% całego snu. Zapis EEG w tej fazie przedstawia fale o niskiej amplitudzie i różnych częstotliwościach. Osoba będąca w tej fazie jest często nieświadoma tego, że śpi i może reagować i odpowiadać na bodźce zewnętrzne [10].



Rysunek 1.5- Faza NREM1. Przewaga fal alfa [11]

1.2.3. Faza NREM2


Faza NREM2 u zdrowych ludzi występuje przez okres ok. 40-50% całego snu. W trakcie tej fazy występuje blokada reagowania na bodźce zewnętrzne. Zapis EEG charakteryzuje się tzw. wrzecionami snu oraz kompleksami K [10].



Rysunek 1.6- Faza NREM 2. Widoczne tzw. wrzeciona snu oraz kompleksy K [11]

1.2.4. Faza NREM3 – sen głęboki


Faza NREM3 jest nazwana fazą snu głębokiego. Wybudzenie pacjenta z tej fazy jest trudne i powoduje dezorientację oraz poczucie wyczerpania. U zdrowych ludzi sen głęboki występuje przez okres ok. 20-25% całego snu. Udział tej fazy maleje wraz z wiekiem. W jej trakcie uwalniany jest hormon wzrostu i następuje regeneracja organizmu [10].



Rysunek 1.7 - Faza NREM3 - sen głęboki [11]

1.2.4. Faza REM – sen paradoksalny


Fazę REM charakteryzują ruchy gałek ocznych. Określa się ją mianem snu paradoksalnego, ponieważ aktywność mózgowa przypomina aktywność podczas fazy czuwania, jednak występuje paraliż mięśniowy. W trakcie tej fazy występują marzenia senne. Udział tej fazy u zdrowych ludzi, podobnie do fazy snu głębokiego, wynosi ok. 20-25% całego snu. Długość faz REM jest krótsza na początku snu, a dłuższa pod jego koniec. Pierwsza faza REM występuje typowo 90-120 minut od zaśnięcia [10].



Rysunek 1.8- Faza REM. W tej fazie występują marzenia senne [11]

1.3. Monitorowanie oddechu

Trzema głównymi metodami monitorowania oddechu są: pomiar ruchu powietrza, rejestracja ruchów klatki piersiowej oraz pomiar saturacji krwi. Ruch powietrza może być rejestrowany przy pomocy termistora reagującego na zmianę temperatury wywołaną jego ogrzaniem przez wydychane powietrze [12][13].



Rysunek 1.9 - Sygnał oddechowy zarejestrowany przy pomocy urządzenia skonstruowanego na bazie termistora [14]

Rozdział 2: Automatyczna analiza faz snu na podstawie sygnału EEG

2.1. Zastosowana metodyka

W celu automatycznej analizy sygnału EEG posłużono się następującą metodyką:

1. Wstępne przetworzenie danych
2. Ekstrakcja cech
3. Klasyfikacja faz snu

Jako metodę ekstrakcji cech użyto dyskretnej transformaty falkowej. W celu klasyfikacji faz snu użyto sieci neuronowej.

2.2. Dyskretna transformacja falkowa

Dyskretna transformacja falkowa jest jedną z metod analizy sygnałów w dziedzinie czasowo-częstotliwościowej. W swojej istocie przypomina transformację Fouriera. Pozwala zapisać sygnał na różnych poziomach szczegółowości przy pomocy falek $\psi_{j,k}$ oraz funkcji skalujących $\varphi_{J,k}$ postaci [15]:

$$y = \sum_k c_{J,k} \varphi_{J,k} + \sum_{j=1}^p \sum_k d_{j,k} \psi_{j,k}. \quad (2.1)$$

Współczynniki $c_{j,k}$ reprezentują aproksymację sygnału na k -tym poziomie. Oblicza się je ze wzoru:

$$c_{j,k} = \sum_n y(n) \varphi_{j,k}(2k - n), \quad (2.2)$$


a współczynniki szczegółowe $d_{j,k}$ kolejnych poziomów dekompozycji określa wzór:

$$d_{j,k} = \sum_n y(n) \psi_{j,k}(2k - n). \quad (2.2)$$

Zbiór falek $\{\psi_{j,k}\}$ określa funkcja:

$$\psi_{j,k}(n) = \frac{1}{\sqrt{2^j}} \psi_k\left(\frac{n - k \cdot 2^j}{2^j}\right), \quad (2.3)$$

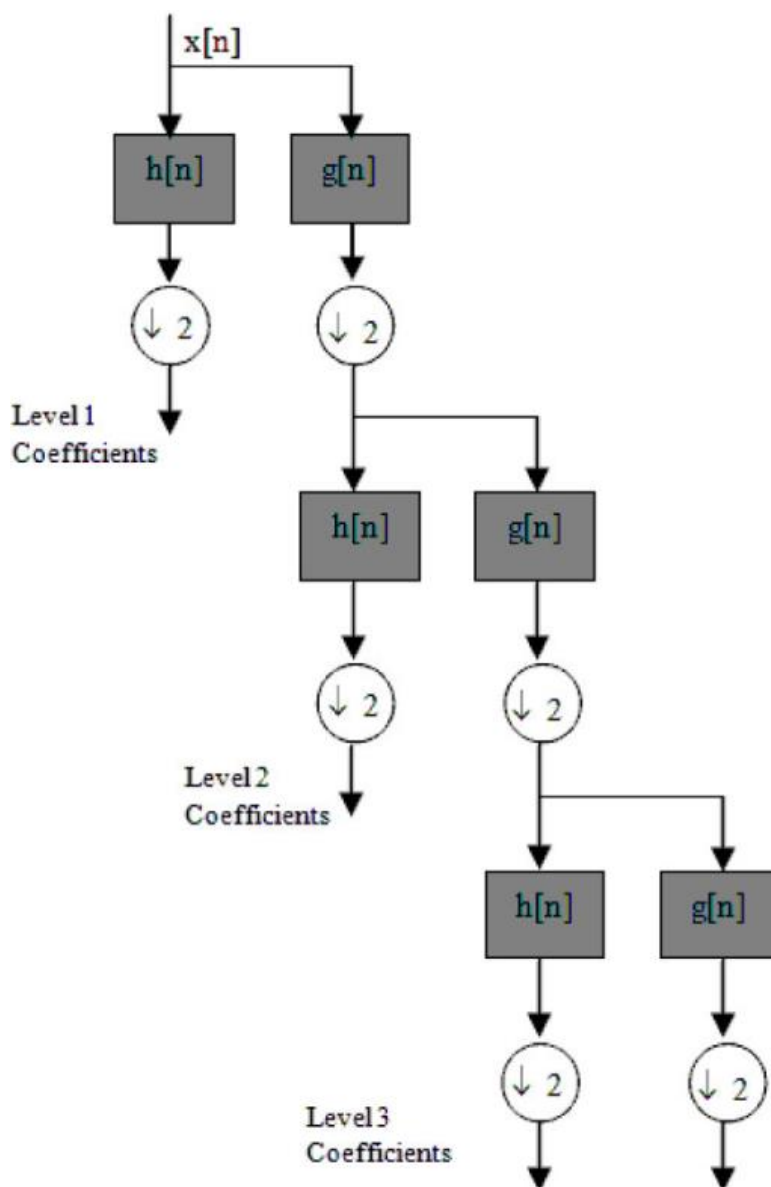
zawierająca liniowo niezależne przebiegi oscylacyjne o zerowej wartości średniej i unormowanej energii - kopie falki matki ψ_k . Są one przesunięte w czasie (k) i są rozciągnięte lub ściśnięte na osi czasu (j -ta potęga 2). Wybór odpowiedniej falki zależy od cech strukturalnych, które są poszukiwane w danych. Jedną z najczęściej używanych falek do ekstrakcji cech sygnału EEG jest falka *Daubechies 4* [16].



Rysunek 2.9 - Falka Daubechies 4 (db4) [17]

Dzięki zastosowaniu DWT sygnał jest dekomponowany na ortogonalne wektory zawierające właściwości sygnału w dziedzinie czasu i skali. Pojedynczy etap dekompozycji polega na przefiltrowaniu sygnału dyskretnego przez zespół filtrów dolno- (h) i

górnoprzepustowych (g). Dzięki downsamplingowi ($\downarrow 2$) algorytm nie wprowadza zmian do długości sygnału. Zespół filtrów układa się w kaskady, by uzyskać wyższe poziomy dekompozycji.




Rysunek 2.2 - Kaskadowa filtracja sygnału [18]

Odpowiedzi impulsowe filtrów wynoszą:

$$\{g_j\} \equiv \{\varphi_j\}, \quad \{h_k\} \equiv \{\psi_j\}. \quad (2.4)$$

2.3. Sztuczne sieci neuronowe

Sztuczne sieci neuronowe są to modele obliczeniowe wzorowane na budowie układu nerwowego, a zwłaszcza mózgu [19]. Zbudowane są z warstw neuronów połączonych ze sobą synapsami, które posiadają określone wagi. Wartość wyjścia każdego neuronu jest obliczana przy pomocy funkcji aktywacji. Przekształca ona pobudzenie wprowadzane na wejściu neuronu. Struktura przykładowej sieci neuronowej przedstawiona jest na Rysunku 2.3.



Rysunek 2.3 - Struktura sieci neuronowej [20]

Warstwa wejściowa reprezentuje dane wejściowe, które są dystrybuowane do głębszych warstw sieci.

Warstwy ukryte umożliwiają sieci tworzenie nowych reprezentacji danych wejściowych wykorzystywanych przez model do nauki złożonych i abstrakcyjnych relacji między etykietami.

Warstwa wyjściowa reprezentuje dane wyjściowe, przetworzone przez sieć neuronową.

Dzięki sieciom neuronowym możliwe jest zaimplementowanie oraz rozwiązanie zadań bez konieczności formułowania i programowania algorytmu [21]. Poddaje się je natomiast procesowi uczenia, który polega na doborze odpowiednich wag. Dzięki swoim zaletom, sztuczne sieci neuronowe okazały się przydatne do analizy faz snu na podstawie sygnałów EEG.

Rozdział 3: Projekt mikroprocesorowego systemu pomiarowego

3.1. Założenia projektowe

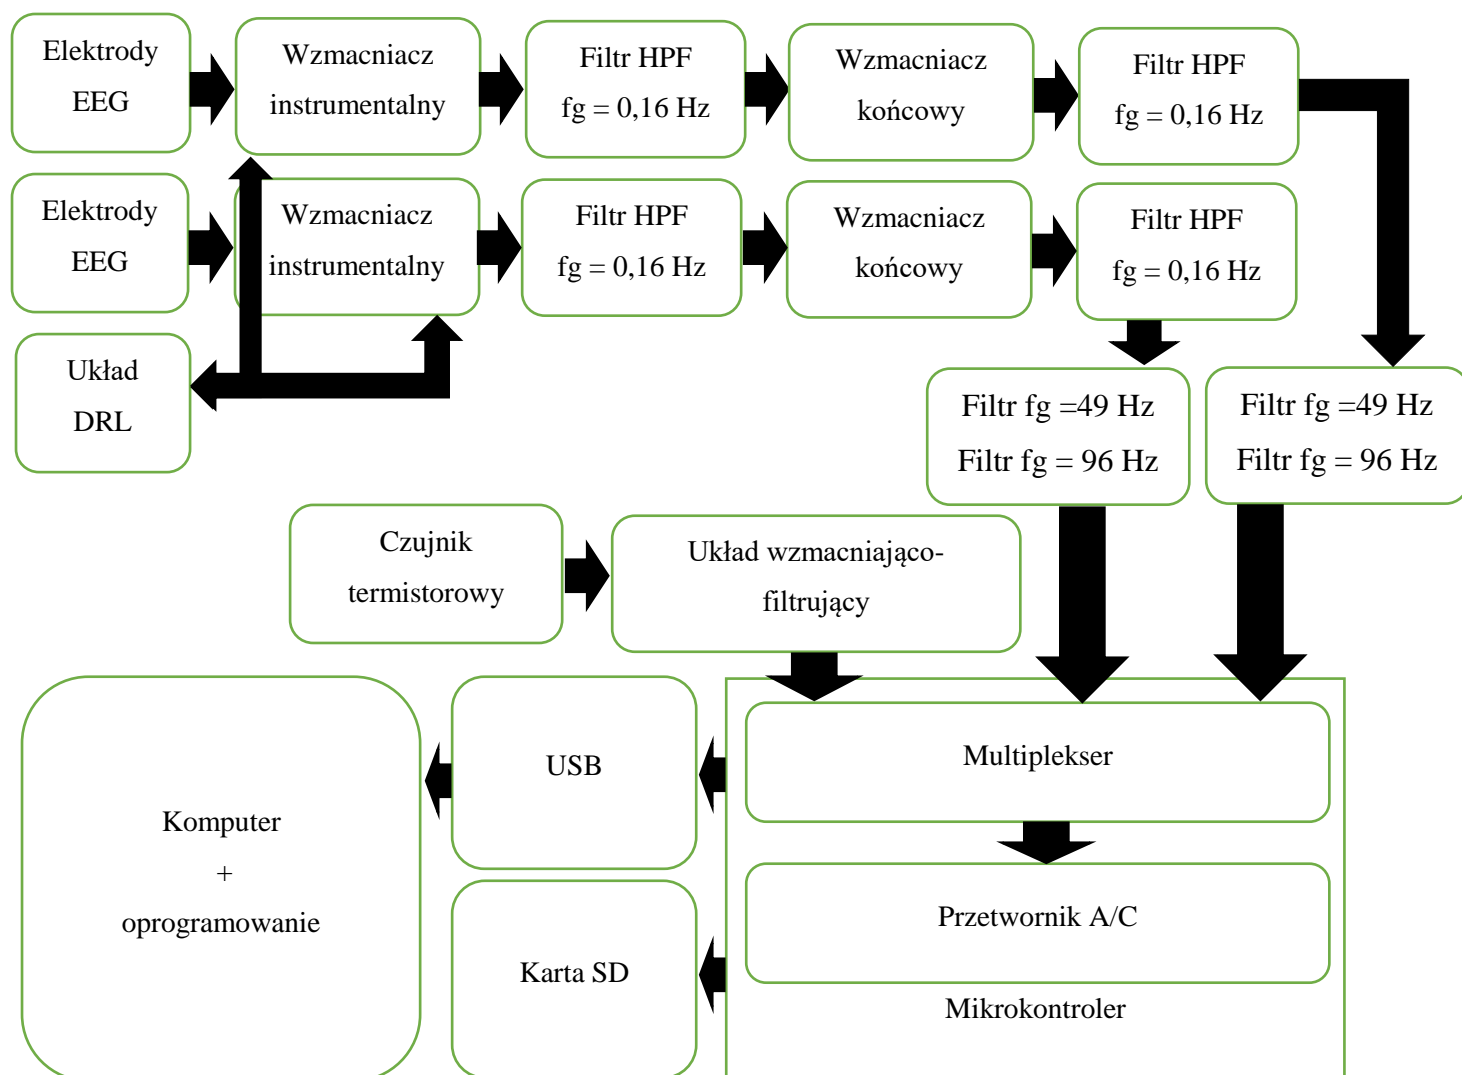
3.1.1. Założenia funkcjonalne

Zadaniem mikroprocesorowego systemu pomiarowego będzie akwizycja danych biomedycznych: fal mózgowych oraz sygnału oddechowego. Bioelektryczna czynność mózgu będzie rejestrowana poprzez dwukanałowy moduł EEG. Elektrody będą umieszczone w konfiguracji C4-A1 oraz C3-A2 w międzynarodowym układzie 10-20 [22]. Detekcja oddechu będzie następowała przy pomocy czujnika zbudowanego na bazie termistora, który będzie umieszczony w maseczce zakładanej na twarz. System będzie zdolny do przekazywania danych bezpośrednio do komputera oraz zasilany przy pomocy USB. Urządzenie winno być skonstruowane w taki sposób, by zapewnić bezpieczeństwo użytkowania. Uzyskane przy pomocy urządzenia dane dotyczące sygnału EEG zostaną poddane analizie wykrywającej stan snu i czuwania.

3.1.2. Założenia konstrukcyjne

Konstrukcja urządzenia będzie oparta na zmodyfikowanym projekcie OpenEEG [23]. Urządzenie będzie składało się z części analogowej oraz cyfrowej. Sygnał EEG będzie rejestrowany przy pomocy pasywnych elektrod suchych przytwierdzonych do głowy pacjenta, a następnie będzie trafiał do zespołu wzmacniacza. Układ powinien być zdolny do akwizycji częstotliwości w zakresie 0-49 Hz, aby być zdolnym do rejestracji fal mózgowych podczas snu oraz być odporny na zakłócenia 50 Hz pochodzące z linii zasilającej [24]. Urządzenie będzie również wyposażone w układ DRL (*driven-right-leg*), który pozwoli zredukować sygnał wspólny za pomocą elektrody umiejscowionej w okolicy wyrostka sutkowego. Z uwagi na to, że zmiany potencjałów elektrycznych na powierzchni skóry głowy są bardzo małe (ich amplituda waha się w zakresie kilku do kilkuset μV), całkowite wzmocnienie układu powinno wynosić co najmniej 7800, by sygnał był użyteczny w zakresie napięcia zasilania 5V [24]. Monitorowanie oddechu będzie realizowane przez dodatkowy kanał analogowy, który również będzie zbudowany przy pomocy wzmacniacza i oparty o pomiar napięcia na termistorze. Wzmocnione i przefiltrowane sygnały biometryczne będą następnie trafiały do przetwornika analogowo-cyfrowego mikrokontrolera Atmega16, który przy pomocy multipleksera będzie

odczytywał sygnał pochodzący z elektrod EEG (ADC0-ADC1) oraz oddechowy (ADC3). Częstotliwość próbkowania sygnałów powinna wynosić co najmniej 100 Hz (nominalnie 256 Hz), by móc rejestrować fale występujące podczas snu. Komunikacja z komputerem będzie zapewniona dzięki modułowi UART, który będzie połączony z układem MAX232. Zapewni to obsługę magistrali USB, przy pomocy wirtualnego portu COM.



Rysunek 3.10 Schemat blokowy proponowanego systemu akwizycji sygnałów EEG i oddechowego

3.1.3. Założenia programistyczne

Oprogramowanie mikrokontrolera powstanie przy użyciu języka C w środowisku *Eclipse* i będzie oparte na rozwiązaniu zaproponowanym przez twórców *OpenEEG*. Dane będą przesyłane do komputera w paczkach 10-bitowych z prędkością 57600 bitów na sekundę w

formacie 1 bit startu, 8 bitów danych, 1 bit stopu, brak bitu parzystości. Dzięki temu uzyska się kompatybilność z protokołem P2, a co za tym idzie oprogramowaniem do akwizycji sygnałów biometrycznych *Openvibe* [25]. Analiza struktury snu zostanie przeprowadzona w środowisku *Matlab* za pomocą dyskretnej transformacji falkowej (DWT) w charakterze metody ekstrakcji cech oraz sztucznej sieci neuronowej (ANN) w charakterze klasyfikatora.

3.2. Moduł EEG

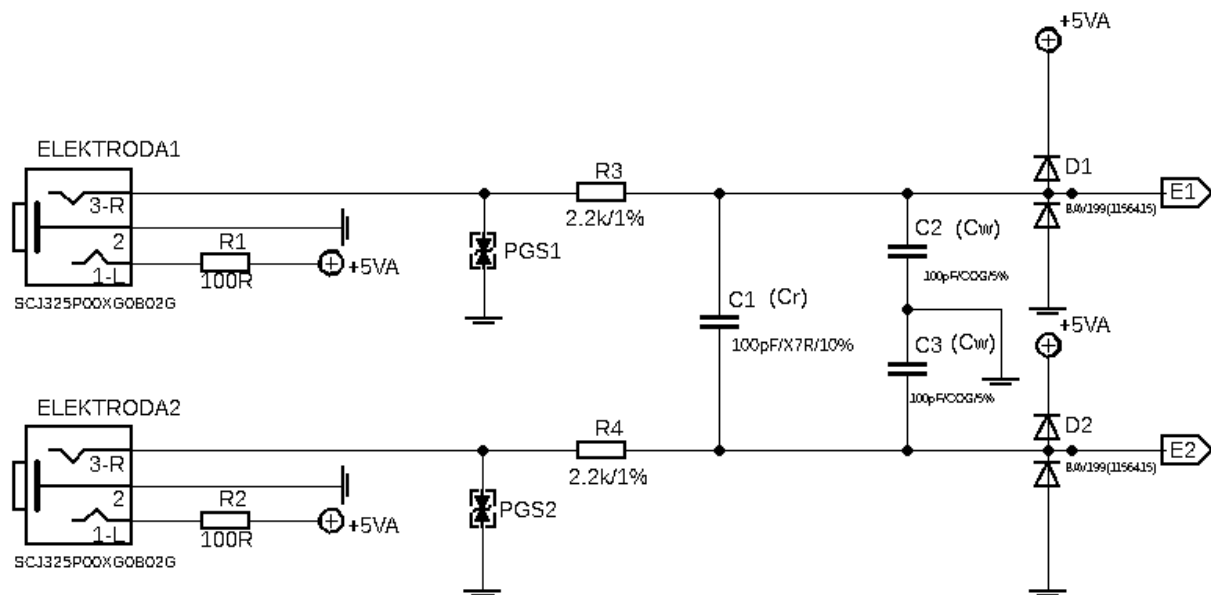
Moduł elektroencefalograficzny został opracowany na bazie zmodyfikowanego projektu OpenEEG [26]. Jego zadaniem jest akwizycja sygnałów bioelektrycznej aktywności mózgu. Do tego celu wykorzystywane są dwa kanały EEG, z których każdy złożony jest z układu zabezpieczająco-filtrującego, wzmacniacza instrumentalnego, wzmacniacza właściwego oraz układu wzmacniająco-filtrującego. W celu minimalizacji wpływu różnego typu zakłóceń, zastosowano również układ sztucznej masy (*driven-right-leg*), wyprowadzony z wejść wzmacniacza instrumentalnego. Przetworzony przy pomocy modułu EEG sygnał trafia do wejścia przetwornika analogowo-cyfrowego mikrokontrolera, zawartego w układzie cyfrowym. Elementy modułu EEG, będącego częścią analogową systemu, zostały opisane poniżej.

3.2.1. Układ zabezpieczająco-filtrujący

Zadaniem układu zabezpieczająco-filtrującego jest odfiltrowanie niepożądanych zakłóceń oraz zabezpieczenie dalszej części układu. Sygnał pochodzący z elektrod jest zabezpieczony przed przepięciami przy pomocy ochronnika. Dodatkowo chroni on pacjenta przed pojawieniem się dużego prądu pomiędzy elektrodami na skutek niewłaściwej pracy urządzenia. Wzmacniacz instrumentalny może ulec uszkodzeniu w przypadku wystąpienia dużej różnicy napięć pomiędzy jego wejściami. W celu jego zabezpieczenia zastosowano diody małosygnałowe. W warunkach normalnej pracy zachowują się one jak obwód otwarty. Jeśli napięcie przekroczy określoną wartość, w przewodniku diody wystąpi przebicie i wejścia zostaną zwarte do masy lub zasilania.

Dodatkowym problemem w przypadku układów biomedycznych jest interferencja fal radiowych. Na wejściu układu może także pojawić się składowa stała związana z dryftem potencjału elektrod, która utrudnia dalsze przetwarzanie sygnału. Aby zminimalizować ten efekt, zastosowano filtry górnoprzepustowe RC ($R3-C1$, $R3-C2$ oraz $R4-C1$ i $R4-C3$). Składają się one z pary rezystorów i kondensatorów na obu wejściach wzmacniacza instrumentalnego

oraz kondensatora podłączonego pomiędzy wejściami. Schemat proponowanego rozwiązania przedstawiony jest na **Błąd! Nie można odnaleźć źródła odwołania.**Rysunek .



Rysunek 3.2 - Schemat układu zabezpieczająco-filtrującego

Zastosowane rozwiązanie pozwala uzyskać dwie częstotliwości graniczne: f_r dla zakłóceń sygnału różnicowego oraz f_w dla sygnału wspólnego. Filtr ogranicza je zgodnie z następującymi zależnościami [27]:

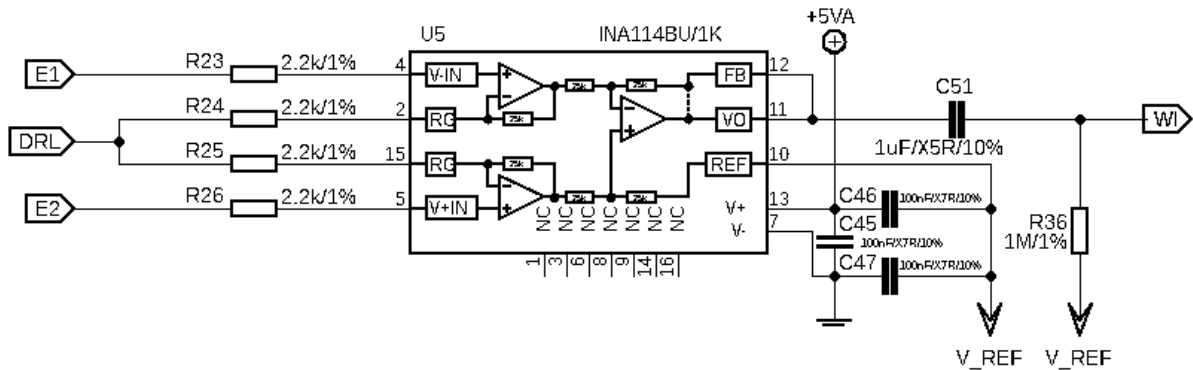
$$f_r = \frac{1}{2\pi R(2C_r + C_w)}, \quad (2.1)$$

$$f_w = \frac{1}{2\pi R C_w} \quad (2.2)$$

Kondensator C_r umieszczony pomiędzy liniami elektrod wpływa na impedancję wejściową wzmacniacza. Jego wartość powinna być niezbyt wysoka i nie przekraczać rzędu setek pikofaradów. Ponadto kondensatory C_w wpływają na impedancję sygnału wspólnego [28]. Dla zastosowanych wartości elementów RC ($R = 2,2k\Omega$, $C_w = C_r = 100 \text{ pF}$) uzyskano częstotliwości graniczne $f_w \approx 723,4 \text{ kHz}$ oraz $f_r \approx 7 \text{ kHz}$, co ma na celu zminimalizowanie wpływu fal radiowych. Dzięki doprowadzeniu do wejść elektrod napięcia zasilania, urządzenie będzie można w przyszłości rozbudować o możliwość zastosowania elektrod aktywnych.

3.2.2 Wzmacniacz instrumentalny

Sygnały biomedyczne, a zwłaszcza te wykorzystywane w elektroencefalografii mają bardzo małą energię. Sprawia to, że są bardzo wrażliwe na



a zakłócenia. W celu zminimalizowania tego efektu, wykorzystano wzmacniacz instrumentalny (pomiarowy), który charakteryzuje się wyższą impedancją i lepszym współczynnikiem CMRR w porównaniu do układu z jednym wzmacniaczem operacyjnym [29]. Jego zadaniem, poza zminimalizowaniem szumu, jest wstępne wzmocnienie sygnału. Schemat układu przedstawia Rysunek 3.3.

Rysunek 3.3 - Schemat układu wzmacniacza instrumentalnego

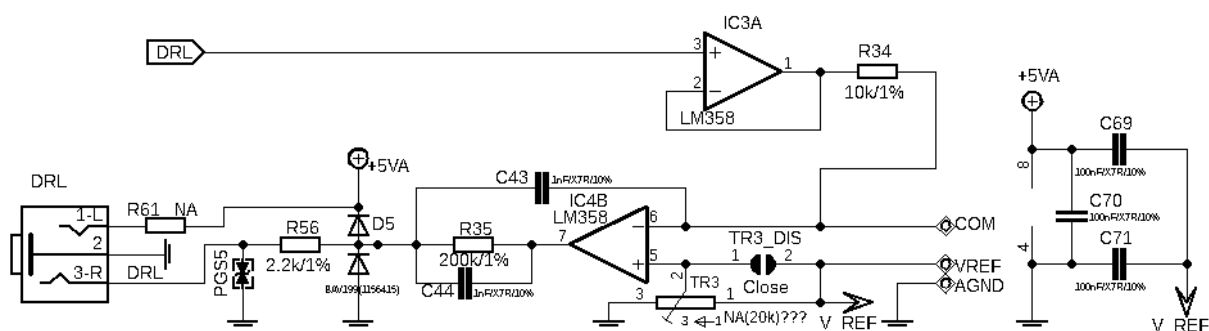
Na jego wyjściu zastosowano filtr górnoprzepustowy RC I-rzędu z częstotliwością graniczną $f_g = 0,16$ Hz przy użyciu rezystora $R11$ oraz kondensatora $C4$. Ma on na celu usunięcie składowej stałej napięcia. Wzmocnienie wzmacniacza wyraża się wzorem [30]:

$$G = \frac{1+50k\Omega}{R8+R9}. \quad (2.3)$$

Dla zastosowanych rezystorów $R8$ i $R9$ wynosi ono $G = 11,59$. Z wejść sygnału wspólnego wyprowadzony jest sygnał do układu sztucznej masy DRL (*driven-right-leg*). Rezystory $R7$ oraz $R10$ zapewniają dopasowanie impedancyjne i powinny być elementami o jak najdokładniejszej tolerancji. Kondensatory $C5$ - $C7$ filtrują zasilanie wzmacniacza.

3.2.3 Układ sztucznej masy DRL

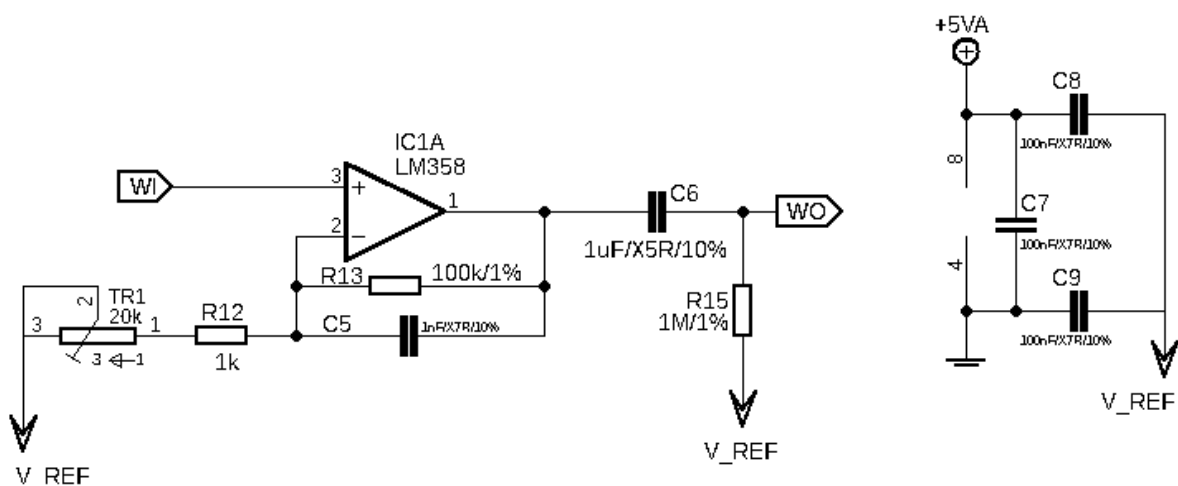
Układ sztucznej masy (*driven right leg*) został zastosowany, by polepszyć tłumienie sygnału wspólnego. Trafiający do układu sygnał podlega odwróceniu fazy i trafia na wyjście dodatkowej elektrody DRL umiejscowionej na wyrostku sutkowatym, stanowiącej punkt odniesienia. Dzięki temu sygnał sieci zasilającej, który w wyniku sprzężenia pojemnościowego jest odbierany przez ciało pacjenta oraz inne składowe wspólne ulegają zmniejszeniu na wejściu układu. W urządzeniu zastosowano układ pochodzący z [31]. Przedstawia go Rysunek 3.4.



Rysunek 3.4 - Układ sztucznej masy DRL

3.2.4 Wzmacniacz właściwy

Układ wzmacniacza właściwego ma za zadanie właściwe wzmocnienie sygnału do poziomów użytecznych do jego późniejszej analizy. Składa się on ze wzmacniacza operacyjnego, a na jego wyjściu umieszczony jest taki sam filtr, jaki zastosowano w układzie wzmacniacza instrumentalnego. Schemat układu przedstawia Rysunek 3.5.



Rysunek 3.5 - Układ wzmacniacza właściwego

Wzmocnienie układu wyraża się wzorem:

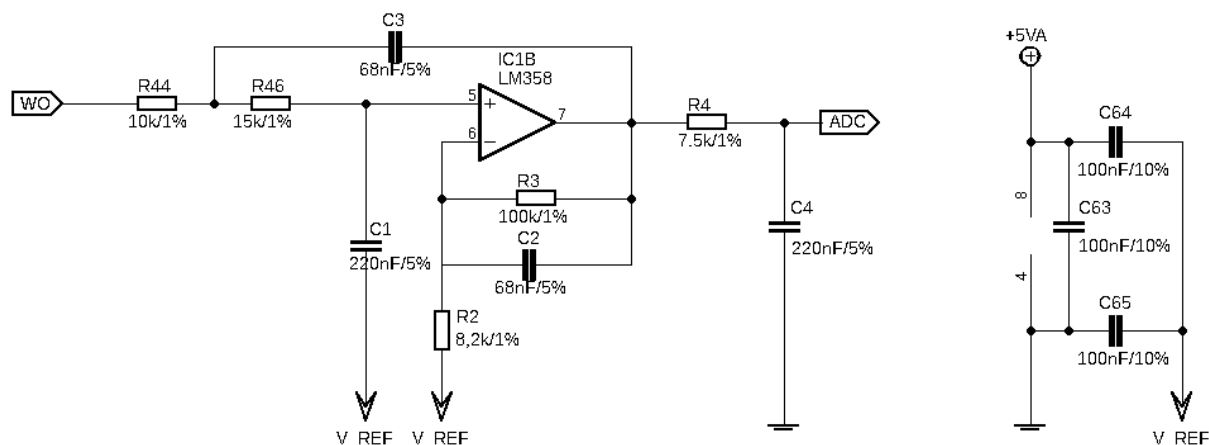
$$G = 1 + \frac{R_{13}}{R_{12} + TR_1}. \quad (2.4)$$

Dla zastosowanych wartości elementów i dzięki umieszczeniu potencjometru, wzmocnienie można regulować w zakresie $G = 6 \dots 101$. Umieszczenie kondensatora w pętli sprzężenia zwrotnego odfiltrowuje częstotliwości powyżej 1 kHz, które mogą prowadzić do występowania zjawiska aliasingu w przetworniku ADC.

3.2.5. Układ filtrująco-wzmacniający

Zadaniem układu filtrująco-wzmacniającego jest ostatnia faza wzmocnienia sygnału oraz odfiltrowanie wyższych częstotliwości. W tym celu zastosowano aktywny filtr dolnoprzepustowy Butterwortha w układzie Sallen Key oraz filtr RC odfiltrowujący częstotliwości powyżej 120 Hz, co ma zapobiec występowaniu zjawiska aliasingu.

Wzmocnienie układu wynosi 16. Kondensatory C63-C65 filtrują zasilanie wzmacniacza. Schemat układu jest przedstawiony na Rysunku 3.6.

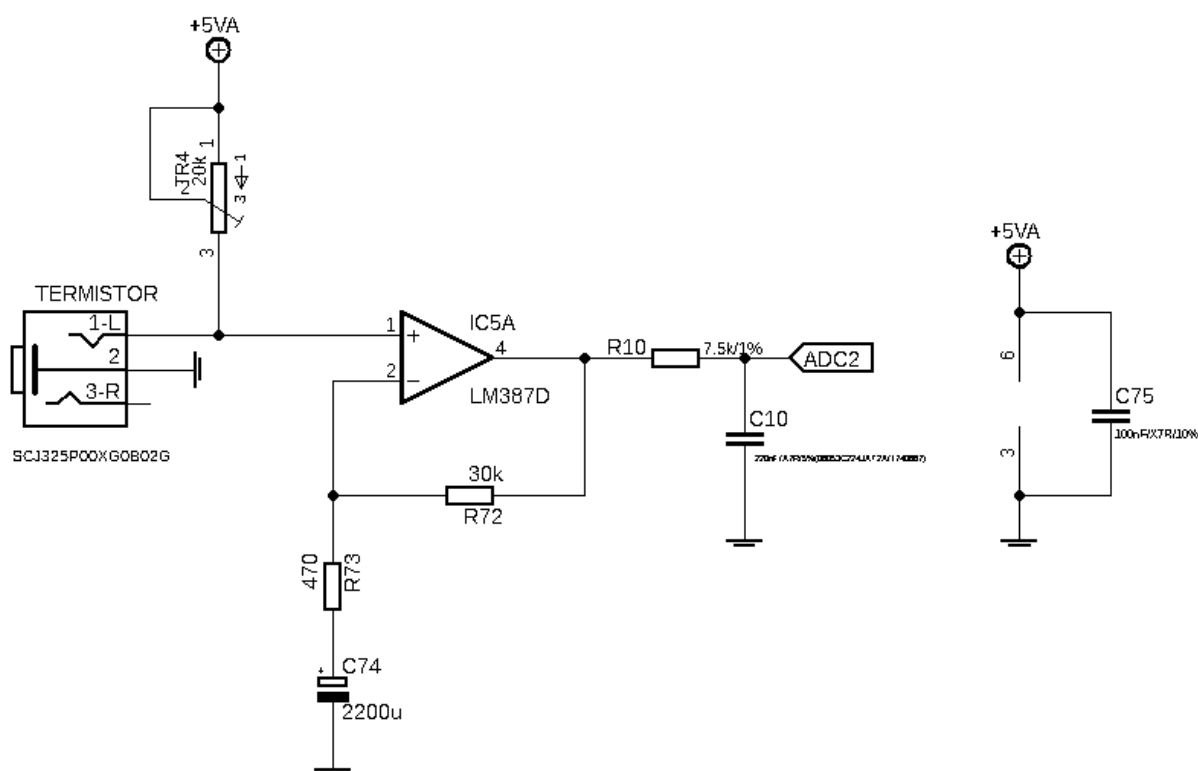


Rysunek 3.6 – Układ filtrująco-wzmacniający

Układ filtrująco – wzmacniający jest ostatnim ogniwem analogowego przetwarzania sygnału i przygotowania do na konwersję analogowo-cyfrową.

3.2.6. Moduł oddechowy

Zadaniem modułu oddechowego jest zapis oddechu pacjenta. Moduł został opracowany na podstawie publikacji [32]. Składa się on z termistora umieszczonego w masce do inhalatora. Reaguje on na zmianę temperatury wywołaną oddychaniem. Sygnał pochodzący z termistora NTC $1\text{ k}\Omega$ jest następnie wzmacniany i trafia do przetwornika analogowo-cyfrowego mikrokontrolera. Wzmocnienie układu wynosi 65. Zastosowany kondensator $C74$ o pojemności $2,2\text{ mF}$ w filtrze górnoprzepustowym zapewnia stałą czasową RC na poziomie 22 sekund, co ma na celu wykrycie normalnego oddechu jak i hiperwentylacji. Zaprojektowany moduł zawiera na wyjściu filtr dolnoprzepustowy zabezpieczający przed występowaniem aliasingu o $f_g=100\text{ Hz}$.



Rysunek 3.7 - Moduł oddechowy


3.3. Symulacje analogowej części systemu

Narzędzia symulacyjne pozwalają na zminimalizowanie błędów jakie mogą się pojawić w przypadku projektowania urządzeń elektronicznych. Do najpopularniejszych z nich należy SPICE (*Simulation Program with Integrated Circuit Emphasis*), który wykorzystuje modele matematyczne do opisanie fizycznych zjawisk w krzemie. Dzięki jego wykorzystaniu, można przewidzieć, w jaki sposób zachowa się zaprojektowany układ przed jego fizycznym

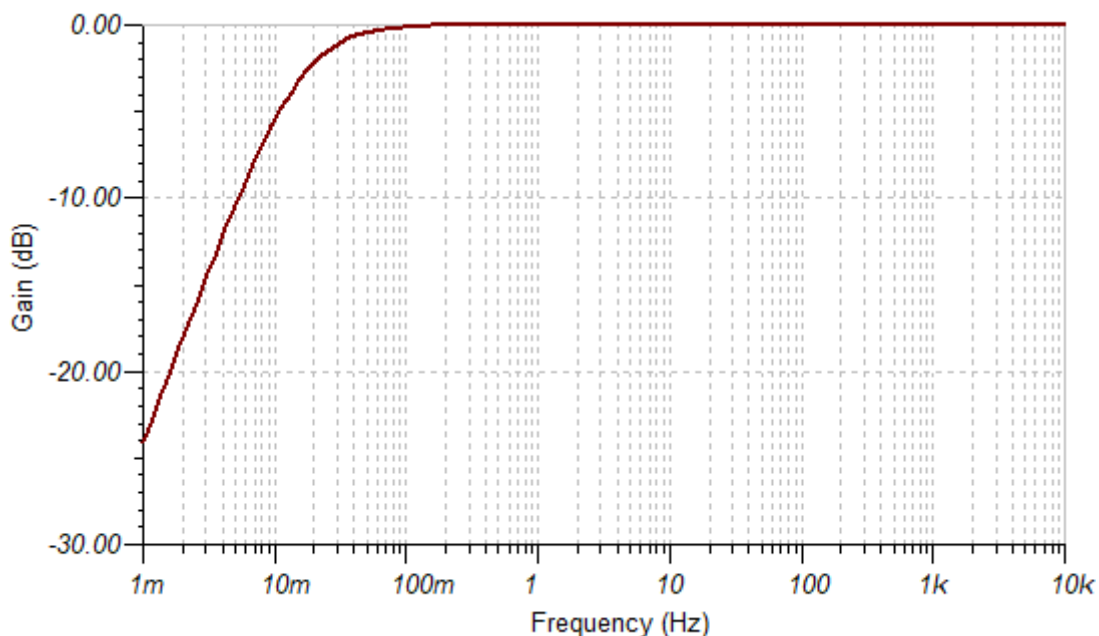
zrealizowaniem. Na potrzeby niniejszej pracy skorzystano z programu Texas Instruments *TINA-TI*, który bazuje na wspomnianym narzędziu.

3.3.1 Układ zabezpieczająco-filtrujący


Celem poniższej symulacji jest przede wszystkim ocena zawartego w układzie filtru górnoprzepustowego. Aktywność bioelektryczną mózgu symuluje generator napięcia, który pobudza układ sygnałem trójkątnym o amplitudzie 5uV i częstotliwości 30 Hz. Jest on podłączony do wejścia analogowej części systemu przez kondensator *C4* 1uF, co ma na celu zasymulowanie sprzężenia pojemnościowego elektrody.



Rysunek 3.8 - Schemat symulacji układu zabezpieczająco-filtrującego



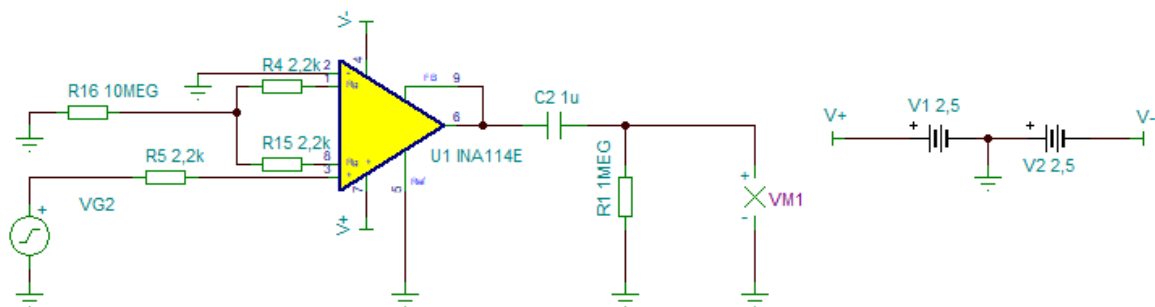
Rysunek 3.11 - Charakterystyka częstotliwościowa układu zabezpieczająco-filtrującego




Rysunek 3.12 - Przesunięcie fazowe układu zabezpieczająco-filtrującego

3.3.2. Wzmacniacz instrumentalny


W celu symulacji układu wzmacniacza instrumentalnego posłużono się dostępnym w programie TINA-TI modelem wzmacniacza INA114. Układ jest pobudzany sygnałem trójkątnym o amplitudzie 5uV i częstotliwości 30 Hz na wejściu nieodwracającym fazy wzmacniacza.



Rysunek 3.13 - Schemat symulacji układu wzmacniacza instrumentalnego



Rysunek 3.14 - Charakterystyka częstotliwościowa układu wzmacniacza instrumentalnego

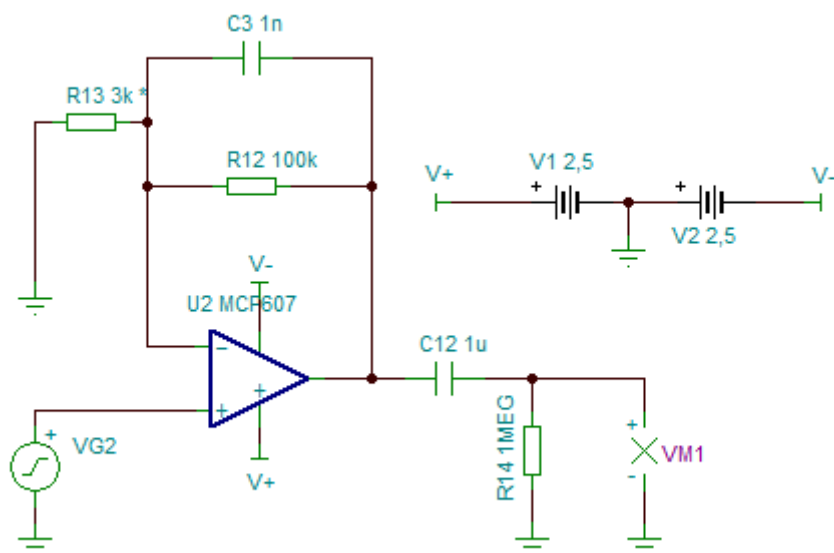


Rysunek 3.15 - Przesunięcie fazowe układu wzmacniacza instrumentalnego


3.3.3. Wzmacniacz właściwy

Symulacja wzmacniacza właściwego uwzględnia różne ustawienia trymera (na schemacie oznaczonego jako *R13*). Generator napięcia pobudza układ sygnałem trójkątnym o


amplitudzie 60 μV i częstotliwości 30 Hz. Ma to na celu zasymulowanie sygnału wzmacnionego przez układ wzmacniacz instrumentalny. Wykresy przedstawiają charakterystyki dla ustawień dla najmniejszego, największego oraz średniego wzmocnienia.



Rysunek 3.16- Schemat symulacji wzmacniacza właściwego



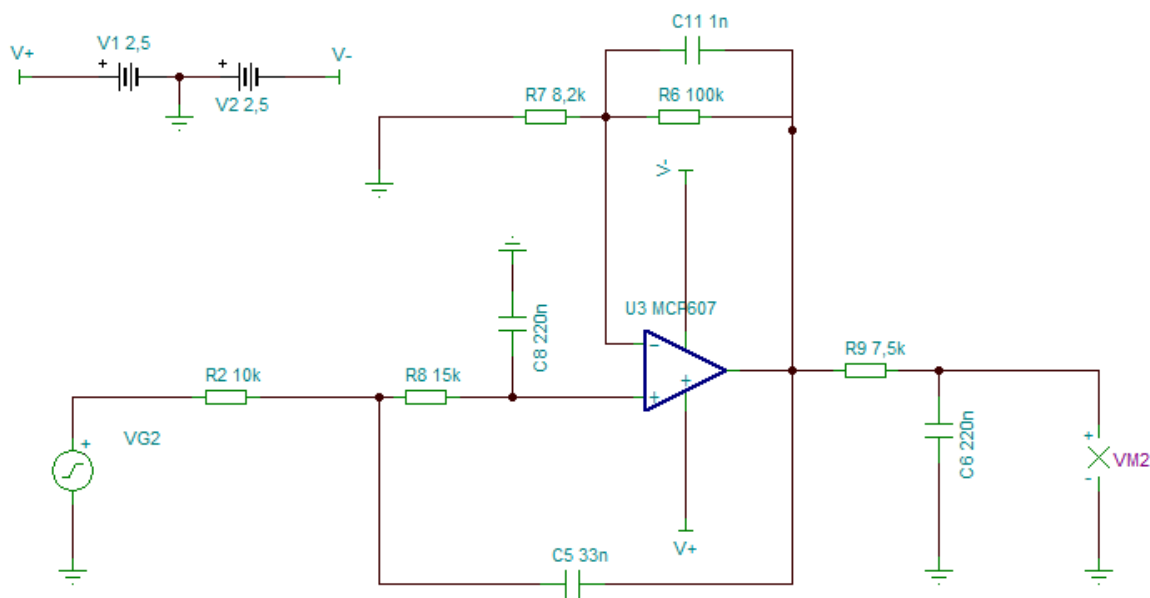
Rysunek 3.17 - Charakterystyka częstotliwościowa wzmacniacza właściwego




Rysunek 3.18 - Przesunięcie fazowe wzmacniacza właściwego

3.3.4 Układ filtrująco-wzmacniający


Symulacja układu filtrująco-wzmacniającego uwzględnia fakt wzmocnienia sygnału na wcześniejszych etapach. Generator napięcia pobudza układ sygnałem trójkątnym o amplitudzie 2 V i częstotliwości 30 Hz.



Rysunek 3.19 - Schemat symulacji układu filtrująco-wzmacniającego



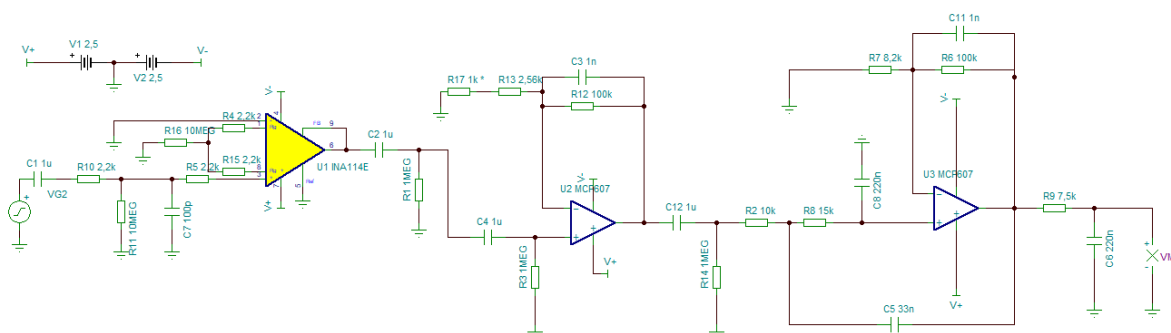
Rysunek 3.20- Charakterystyka częstotliwościowa układu filtrująco-wzmacniającego




Rysunek 3.21 - Przesunięcie fazowe układu filtrująco-wzmacniającego

3.3.5. Symulacja pełnego toru akwizycji sygnału EEG


W celu sprawdzenia jak zachowa się cały układ akwizycji sygnału EEG, przeprowadzono symulację uwzględniającą wszystkie moduły. Schemat symulacji przedstawiony jest na Rysunku 3.20. Rezystor $R17$ symbolizuje trymer do ustawiania wzmocnienia układu. Analizę przeprowadzono dla wartości 0 oraz 20k Ω .



Rysunek 3.22 - Schemat symulacji pełnego toru akwizycji sygnału EEG



Rysunek 3.23- Charakterystyka częstotliwościowa pełnego toru akwizycji sygnału EEG

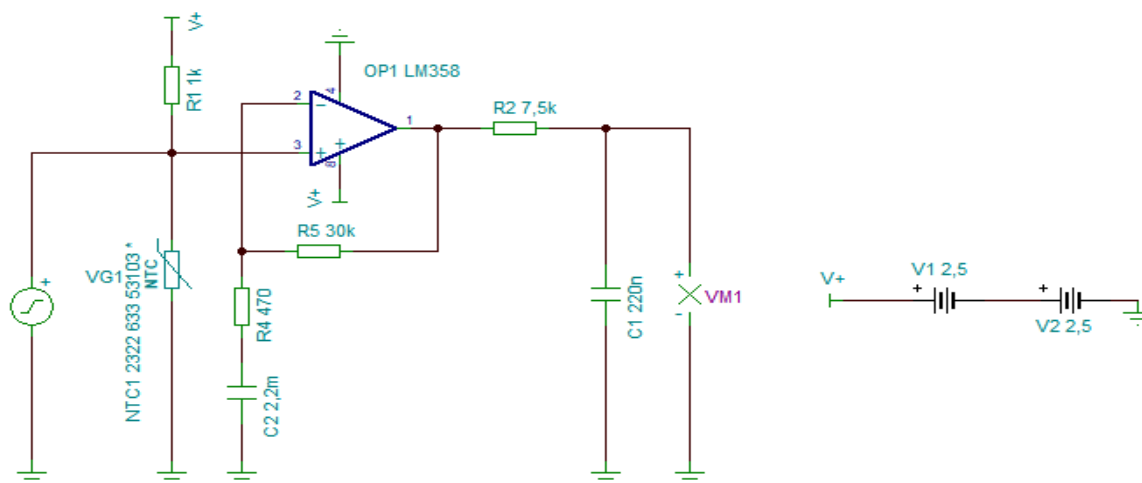


Rysunek 3.24- Przesunięcie fazowe pełnego toru akwizycji sygnału EEG


Maksymalne wzmocnienie sygnału wynosi ok. 80 dB i występuje dla częstotliwości w zakresie 1-50 Hz. Wyniki symulacji wskazują, że urządzenie powinno spełnić wymagania przedstawione w Rozdziale 1.

3.3.6. Symulacja układu wzmacniająco-filtrującego modułu oddechowego


W celu symulacji układu wzmacniająco-filtrującego modułu oddechowego posłużono się programem TINA-TI. Schemat i wyniki symulacji przedstawiają rysunki poniżej.



Rysunek 3.25- Schemat symulacji układu wzmacniająco-filtrującego modułu oddechowego




Rysunek 3.26 - Charakterystyka częstotliwościowa układu wzmacniająco-filtrującego modułu oddechowego



Rysunek 3.27 - Przesunięcie fazowe układu wzmacniająco-filtrującego modułu oddechowego

3.4. Filtr zasilania

Zasilanie układu podzielono na część analogową oraz cyfrową. Filtracja zasilania każdej części jest zrealizowana przy pomocy zestawu kondensatorów: tantalowego o pojemności 47 μF (C29, C26) który charakteryzuje się wysoką pojemnością i niską impedancją szeregową oraz ceramicznych o mniejszej pojemności, które mają za zadanie eliminację szpilek napięciowych: 100 nF (C28, C25) oraz 10 nF (C27, C24). Układ jest także złożony z dławików ferrytowych 22 μH , które utrudniają przenikanie zakłóceń pomiędzy częścią analogową i cyfrową zasilania. Część analogowa zawiera również diodę Zenera Z1 (BZV55C6V2), która jest użyta jako transil tłumiący przepięcia i impulsy o wysokim napięciu. Do napięcia wejściowego jest równolegle podłączona dioda LED sygnalizująca pracę urządzenia. Rezystor R62 = 560 Ω ma na celu ograniczenie jej prądu, czyli zabezpieczenie przed spalaniem.



Rysunek 3.28- Filtr zasilania

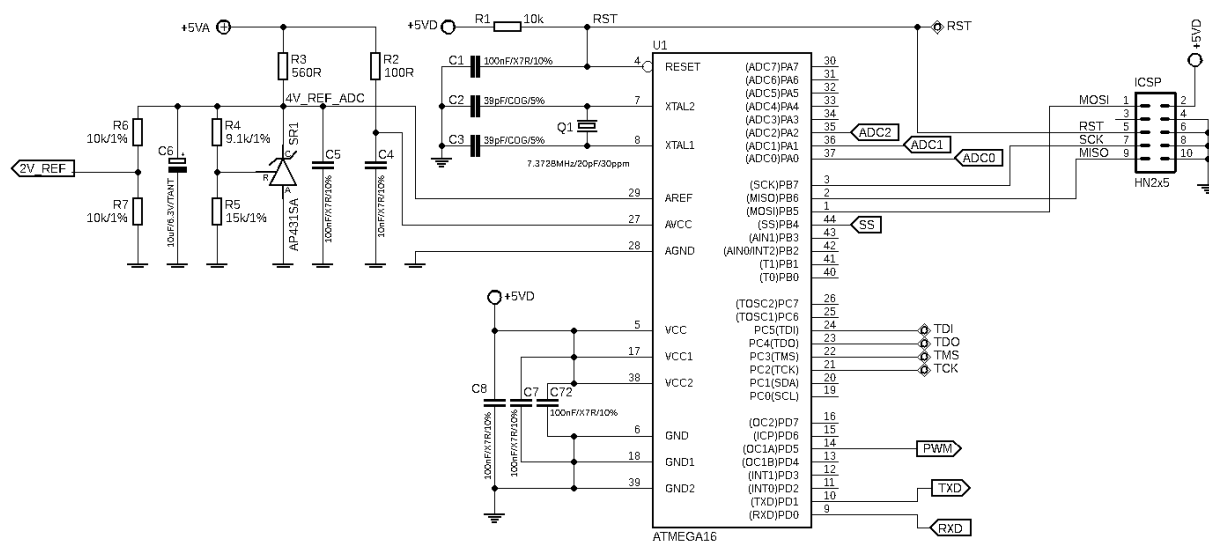
3.5. Moduł mikrokontrolera

Sercem części cyfrowej urządzenia jest mikrokontroler Atmega16 z rodziny AVR. Został on zastosowany ze względu na niski koszt oraz fakt posiadania przez niego interfejsów UART, SPI oraz 10-bitowego przetwornika ADC. Jest to chip, który nie wymaga drogiego i specjalistycznego programatora.

Filtracja zasilania tego układu jest realizowana poprzez kondensatory ceramiczne o pojemności 100 nF, które zapewniają wygładzanie napięcia zasilania dla każdego wejścia VCC (C8 C7, C72). Do wejścia RESET (PIN 4) podpięto rezystor podciągający $R1 = 10 \text{ k}\Omega$, który zabezpiecza przed występowaniem na tym pinie stanu nieustalonego, który potencjalnie

Zasilanie przetwornika analogowo-cyfrowego (AVCC) jest doprowadzone przez rezystor $R2 = 100 \, \Omega$ i filtrowane przez kondensator $C4$. Napięcie referencyjne jest stabilizowane przez układ AP431SAN1TR-G1 i wyraża się zależnością [33]:


Dzielnik złożony z rezystorów $R3$ oraz $R = R4 + R5$ obniża napięcie źródła referencyjnego V_{rin} z 5V do 4,86 V, aby zminimalizować możliwość odcięcia części sygnału trafiającego do przetwornika ADC. Przy użyciu dzielnika złożonego z rezystorów $R6$ oraz $R7$ uzyskuje się napięcie 2,43 V, które posłuży jako punkt odniesienia dla sygnałów pochodzących z elektrod (2V REF).



3.6. Wtórnik napięcia referencyjnego sygnału EEG

33


referencyjnego. Jest to kluczowe w przypadku analizowania sygnałów o małej mocy. Różnice potencjałów powodowanych aktywnością bioelektryczną mózgu będą rejestrowane w odniesieniu do napięcia V_{REF} .



Rysunek 3.30 - Wtórnik napięcia referencyjnego sygnału EEG

3.7. Kalibrator wzmacnienia

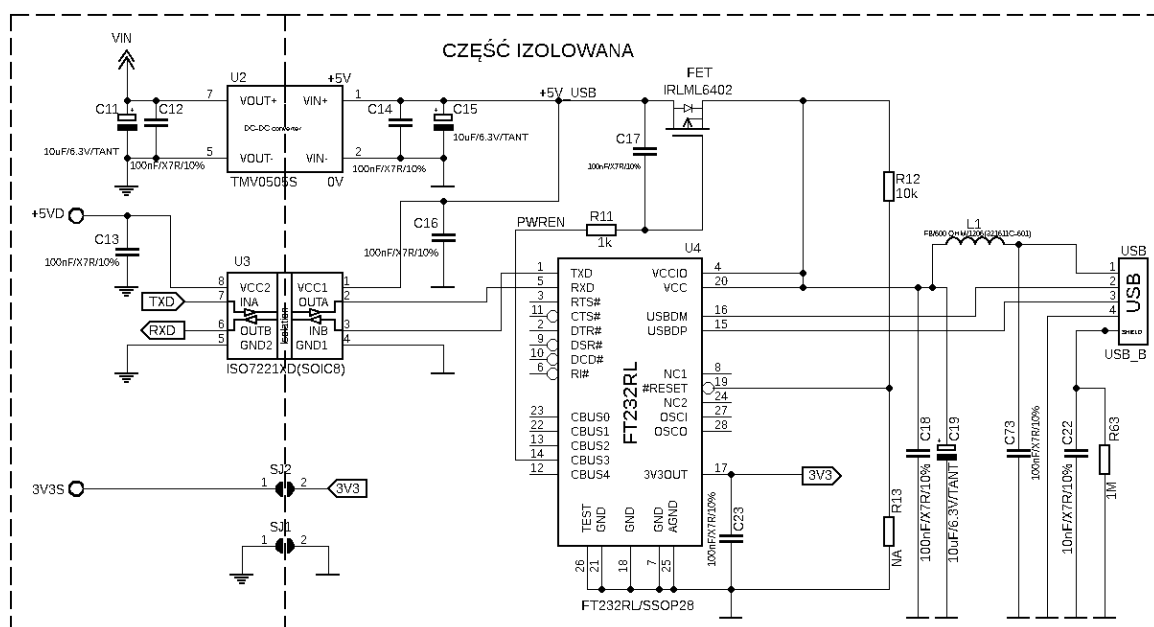
Kalibrator wzmacnienia będzie użyty w celu kalibracji wzmacnienia poszczególnych kanałów sygnału EEG. Jest to dzielnik napięciowy, który ma za zadanie zmniejszenie amplitudy sygnału PWM do wartości ok. 250 μ V. Uzyskany w ten sposób sygnał o przebiegu trójkątnym będzie można skierować na wejście poszczególnego kanału wzmacniacza instrumentalnego. Przy użyciu trymerów TR1 oraz TR2 będzie można dostosować wzmacnienie układu wzmacniacza obserwując sygnał rejestrowany przez urządzenie.



Rysunek 3.31- Kalibrator wzmacnienia

3.8. Izolowany moduł komunikacyjny

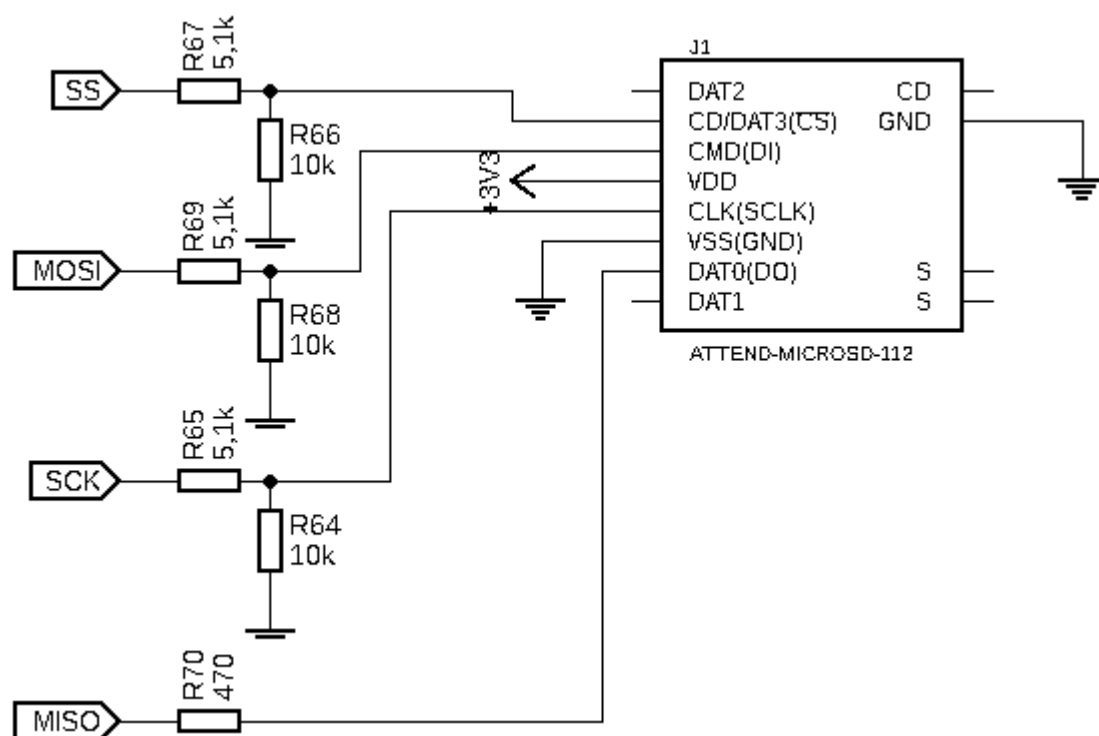
Komunikację układu zapewnia konwerter USB – UART oparty na FT232RL. Został on skonstruowany w zgodzie z wytycznymi zawartymi w nocie katalogowej [34]. W celu zapewnienia bezpieczeństwa użytkownika zastosowano przetwornik DC/DC TMV0505S izolujący zasilanie dalszej części układu. Komunikacja z modułem UART mikrokontrolera jest realizowana poprzez separator galwaniczny ISO7221AD. Zasilanie karty SD można uzyskać jedynie zasilając urządzenie podłączając baterię do złącza USB i zwierając zworki SJ1 i SJ2. Wówczas układ FT232RL posłuży do zapewnienia napięcia 3,3 V, niezbędnego do zasilenia karty SD. Zwarcie tych zworek niweluje izolację galwaniczną i jest odradzane, gdy urządzenie jest podłączone do komputera.



Rysunek 3.32- Izolowany moduł komunikacyjny

3.9. Karta microSD

Do interfejsu SPI mikrokontrolera zostało podłączone złącze karty SD. Dostosowanie poziomów napięć do poziomu 3,3 V jest realizowane przez dzielniki napięciowe zbudowane z par rezystorów *R66- R67*, *R68-R69*, *R64-R65*. Dzięki temu możliwe jest korzystanie z urządzenia bez konieczności podłączania do komputera.



Rysunek 3.33 - Złącze karty SD


Rozwiązanie to nie zostało jednak przetestowane. Aby to zrobić, należałoby zastosować pojemną baterię o napięciu 5V, którą należałoby podłączyć do złącza USB.

Rozdział 4: Realizacja modelu urządzenia

4.1. Projekt urządzenia

4.1.1. Prototyp urządzenia EEG


Po zaprojektowaniu i wykonaniu symulacji układu przystąpiono do realizacji prototypu z elementów przewlekanych. Dzięki temu zamiana poszczególnych elementów na ich odpowiedniki była łatwiejsza w przypadku wystąpienia takiej konieczności. Projekt płytki powstał w programie *Eagle* rozwijanego przez firmę *Autodesk*. Prototyp powstał przy wykorzystaniu metody termotransferu, a płytka została wykonana samodzielnie przez autora pracy.



Rysunek 4.34- Wczesny prototyp części analogowej systemu

4.1.2. Prototyp modułu oddechowego


W trakcie projektowania zmontowano układ na płytce stykowej, a następnie przy pomocy oscyloskopu sprawdzono, czy układ dostatecznie wzmacnia sygnał z termistora. W trakcie procedury dostosowano wartość wzmocnienia układu w ten sposób, by mieścił się on w zakresie 0 – 5V. Podczas testów nie zaobserwowano przesterowania wzmocnionego sygnału.




Rysunek 4.35 - Prototyp modułu oddechowego zmontowany na płytce stykowej

4.2. Projekt i wykonanie płytek PCB w technologii SMT


Projekt płytki PCB gotowego urządzenia jest modyfikacją rozwiązania zaproponowanego przez firmę Olimex [35] i powstał w programie *Eagle* rozwijanego przez firmę *Autodesk*. W porównaniu do oryginału dodano moduł oddechowy oraz kartę SD i zastąpiono część elementów ich odpowiednikami. Ze względu na mniejsze rozmiary płytki, a co za tym idzie zmniejszenie kosztów, zdecydowano się ostatecznie na technologię SMD. Fizyczna realizacja płytki PCB urządzenia została zlecona firmie zewnętrznej, a montaż elementów i wykonanie elektrod zostały w całości zrealizowane przez autora pracy.




Rysunek 4.36 - Płytki PCB urządzenia – część górna




Rysunek 4.37 - Płytki PCB urządzenia - część dolna



Rysunek 4.38 - Gotowe urządzenie - część górna



Rysunek 4.39 - Gotowe urządzenie - część dolna



Rysunek 4.40 - Płytki PCB elektrod oraz gotowe elektrody



Rysunek 4.41 - Maska respiratora z zainstalowanym termistorem


4.3. Oprogramowanie układu

Program do obsługi urządzenia bazuje na firmware w wersji P2 dostępnym na stronie projektu OpenEEG autorstwa Joerga Hansmanna, Jima Petersa i Andreasa Robinsona. Został on dostosowany do architektury mikrokontrolera Atmega 16 oraz zmodyfikowany w taki sposób, by obsługiwał również dodatkowy przetwornik ADC obsługujący moduł oddechowy. Firmware został wgrany przy użyciu modułu USBasp oraz programu AVRDUDE za pośrednictwem interfejsu SPI.

4.4. Testy gotowego urządzenia

4.4.1. Test modułu EEG


Każdy z torów analogowych akwizycji EEG został pobudzony sygnałami o różnym przebiegu i częstotliwości 30 Hz z generatora - *Minikombajnu pomiarowego AVT2999*. W celu zmniejszenia amplitudy sygnału użyto dzielnika napięcia 1:20000, który zmniejszył amplitudę do poziomu kilkuset μV . Przy pomocy oscyloskopu *Siglent SDS 1202X-E* obserwowano przebieg na wyjściu układu. Wynik testu okazał się pozytywny – zadany sygnał został wzmacniony.



Rysunek 4.42 - Sygnał na wyjściu prototypu urządzenia przy pobudzeniu sygnałem sinusoidalnym o częstotliwości 30 Hz

Po zmontowaniu i zaprogramowaniu układu przystąpiono do testu gotowego urządzenia. W tym celu zdecydowano się na próbę rejestracji czynności serca. Sygnał EKG podobnie do sygnału EEG jest sygnałem biomedycznym i jego przebieg można z łatwością rozpoznać. Elektrody pomiarowe zostały umiejscowione na zgięciu łokcia, a elektroda DRL na brzuchu. Do wejścia kanału drugiego doprowadzono elektrody przytwierdzone do czoła. Urządzenie zostało następnie podłączone do komputera. Do wizualizacji danych użyto programu *ElectricGuru*, który wyświetla próbki w przedziale 10-bitowym (0-1024). Na


podstawie wzrokowej analizy sygnału kanału 1 rozpoznano odstęp PQ oraz QT sygnału EKG. Wynik testu przedstawia rysunek poniżej.



Rysunek 4.43- Wizualizacja danych biomedycznych uzyskanych podczas testu gotowego urządzenia

4.4.2. Test modułu oddechowego

Układ filtrująco-wzmacniający modułu oddechowego został w całości zestawiony na płycie stykowej i sprawdzony przy pomocy oscyloskopu.



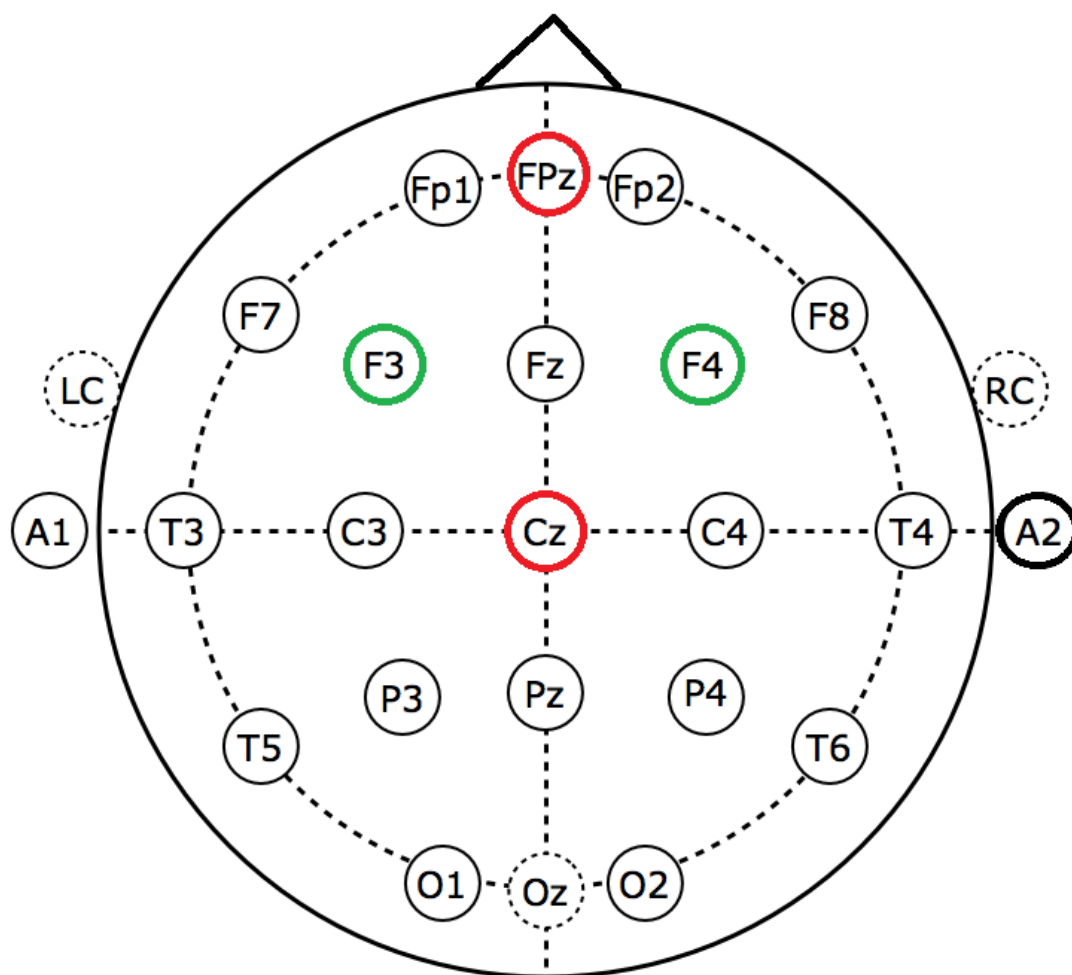
Rysunek 4.44 - Sygnał na wyjściu modułu oddechowego

Wynik testu okazał się pozytywny – wzmacnienie układu okazało się wystarczające do obserwacji cyklu oddechowego.

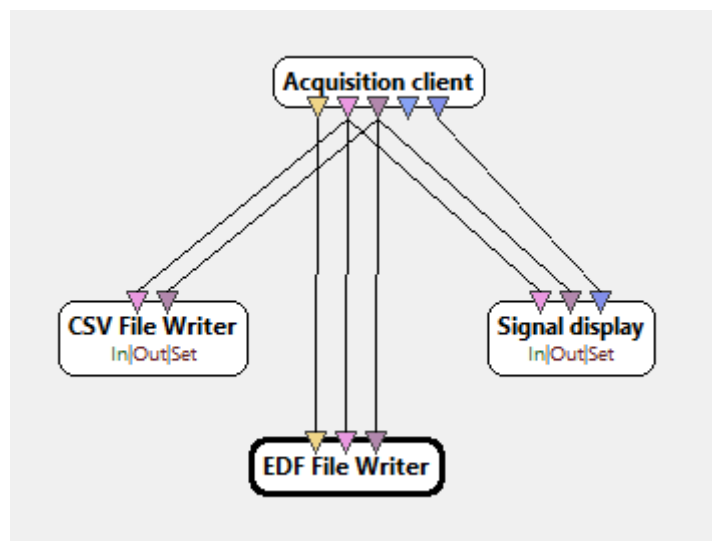
4.5. Akwizycja sygnału EEG

Po przeprowadzeniu testów przystąpiono do akwizycji sygnału EEG podczas snu. Dla celów minimalizacji dyskomfortu związanego z przeprowadzoną procedurą, zrezygnowano na tym etapie z rejestrowania sygnału oddechowego przy pomocy maski z termistorem. Okres akwizycji wynosił kilkanaście dni, z czego do dalszej analizy wybrano jeden zapis. Elektrody zostały umiejscowione w międzynarodowym systemie lokalizacji elektrod EEG 10-20 [36] w następujący sposób:

- Kanał 1: F3 – F4
- Kanał 2: Fpz – Cz



Konfiguracja *Fpz – Cz* została wybrana, by zachować zgodność z metodologią badań zawartych w bazie *PhysioNet Sleep Database* [38], które posłużą jako zestaw danych wzorcowych do analizy faz snu. W pozycji A2 umiejscowiona została elektroda DRL. Z powodu obaw o wpływ włosów na jakość pozyskiwanego sygnału zastosowano żel przewodzący oraz gumkę dociskającą do głowy w pozycji Cz. W miejsce użytej w danych wzorcowych lokalizacji *Pz-Oz*, posłużono się konfiguracją *F3-F4*. Dzięki temu obie elektrody na wejściu kanału pierwszego były bliżej skóry. W trakcie procedury wykorzystano program *OpenVibe*, który umożliwia zapis pozyskanych danych do plików *.csv* oraz *.edf*. Ze względu na przenoszenie zakłóceń z sieci energetycznej, zastosowano zasilanie z baterii laptopa. Umożliwiło ono zapis ponad 2 godzin sygnału.




Rysunek 4.46 - Struktura scenariusza w programie *OpenVibe* użytego w celu akwizycji danych




Rysunek 4.47 - Przygotowanie do akwizycji sygnału EEG


Zapis w celu wstępnej weryfikacji poprawności otworzono następnie w programie *EDFBrowser* [39]. W wyniku tej procedury zdecydowano, że do celów dalszej analizy posłuży jedynie sygnał z kanału z elektrod *F3-F4*. Rysunki poniżej przedstawiają przykładowy zapis uzyskany przy pomocy skonstruowanego urządzenia w różnych momentach czasowych nagrania.




Rysunek 4.48- Zapis sygnału EEG w 10 minucie 28 sekundzie od momentu rozpoczęcia




Rysunek 4.49 - Zapis sygnału EEG w 29 minucie 35 sekundzie od momentu rozpoczęcia



Rysunek 4.50 - Zapis sygnału EEG w 32 minucie 17 sekundzie od momentu rozpoczęcia




Rysunek 4.51 - Zapis sygnału EEG w 43 minucie 25 sekundzie od momentu rozpoczęcia




Rysunek 4.52 - Zapis sygnału w 58 minucie 42 sekundzie od jego rozpoczęcia

Na podstawie wzrokowej analizy sygnału stwierdzono, że wraz z trwaniem nagrania częstotliwość zarejestrowanych fal maleje, a ich amplituda rośnie. Zanotowano również artefakty, które najprawdopodobniej są wynikiem zmiany pozycji ciała podczas snu. Rysunek poniżej przedstawia przykładowy artefakt zanotowany w zapisie. W dalszej fazie należy uwzględnić fakt ich występowania i wpływ na wynik analizy struktury snu.



Rysunek 4.53 - Zapis artefaktu związanego prawdopodobnie ze zmianą pozycji ciała w 4 minucie 30 sekundzie nagrania



Rysunek 4.54- Pelen zapis nagrania: 59 minut 32 sekundy

Rozdział 5: Analiza struktury snu

5.1. Import wzorcowych danych z bazy PhysioNet

Wykorzystano dane wzorcowe wykorzystane wcześniej w [40] pobrane z bazy *PhysioNet The Sleep-EDF Database* [38]. Baza ta zawiera dane polisomnograficzne próbkowane z częstotliwością 100 Hz pochodzące od różnych pacjentów. Obróbka danych została wykonana w programie *Matlab* firmy *Mathworks*. Dane zostały przekonwertowane z plików *.edf* na pliki *.mat* oraz podzielone na 30 sekundowe epoki zawierające zapisy EEG. Każda z wyodrębnionych epok przypisana jest do poszczególnych faz snu: W, NREM1, NREM2, SWS (NREM3, NREM4) i REM. Epoki, w których zaznaczono kilka faz równocześnie zostały odrzucone. Wykorzystano dane pochodzące od 37 pacjentów.

We wstępnej fazie dane zostały poddane normalizacji do zakresu od -1 do 1, by można było porównywać zapisy pochodzące od różnych osób z tymi zarejestrowanymi przez urządzenie skonstruowane na potrzeby tej pracy. W tym celu skorzystano z polecenia:

```
% Normalizacja
[epoka_norm ps] = mapminmax(epoka', -1, 1);
```

5.2. Implementacja metody ekstrakcji cech

Ekstrakcja cech została wykonana przy użyciu algorytmu dyskretnej transformaty falkowej (DWT) przy użyciu falki *Daubechies 4 (db4)* jako jednej z najczęściej stosowanych w charakterze dekompozycji sygnałów biomedycznych [41]. Z uwagi na użyteczność sygnału w zakresie od 0,5 do 50 Hz, zastosowano 4 poziomy dekompozycji [40].

```
% Dekompozycja sygnału
[c0, l0] = wavedec(epoka, 5, 'db4');

% Współczynniki dla epoki
cD1 = detcoef(c0,l0,1); %25 - 50 Hz
cD2 = detcoef(c0,l0,2); %12.5 - 25 Hz
cD3 = detcoef(c0,l0,3); %6.25 - 12.5 Hz
cD4 = detcoef(c0,l0,4); %3.125 - 6.25 Hz
cA4 = appcoef(c0,l0, 'db4', 5); % 0 - 3.125 Hz
```

Następnie dla każdego badanego zakresu obliczono średnią moc (wyrażoną w decybelach) oraz ich ilorazy. Wartości te posłużyły następnie do stworzenia wektora obranej metody klasyfikacyjnej, czyli sztucznej sieci neuronowej.

```

% Średnia moc współczynników
PD1 = 10*log10 (sumsqr (cD1) /length (cD1));
PD2 = 10*log10 (sumsqr (cD2) /length (cD2));
PD3 = 10*log10 (sumsqr (cD3) /length (cD3));
PD4 = 10*log10 (sumsqr (cD4) /length (cD4));
PA4 = 10*log10 (sumsqr (cA5) /length (cA5));

% Ilorazy
SD1(:,i) = PD1(:,i) /PD2(:,i);
SD2(:,i) = PD2(:,i) /PD3(:,i);
SD3(:,i) = PD3(:,i) /PD4(:,i);
SD4(:,i) = PD4(:,i) /PA5(:,i);

% Wektor epoki do klasyfikacji
wektor = [PD1, SD1, PD2, SD2, PD3, SD3, PD4, SD4, PA5];

```

W wyniku tej operacji uzyskano 9-elementowe wektory wejściowe dla każdej z epok zapisane w macierzach *wektory_F* (dla zapisu Fpz-Cz) oraz *wektory_P* (dla zapisu Pz-Oz). Fazy snu każdego z pacjentów zostały zapisane w macierzy *fazy_snu*.

Tabela 1 – Liczba epok odpowiadająca określonym fazom snu

Faza snu	Liczba epok
Wybudzenie	66923
NREM1	2644
NREM2	16087
SWS	4942
REM	7073
SUMA	97669

W celu podziału danych wejściowych na równe ilościowo klasy, wylosowano wybrane epoki, by poprzez dostosowanie się do liczby epok fazy NREM1, udział każdej fazy snu był jednakowy. Wynosi on (dla każdej fazy snu zarejestrowanej przy pomocy 2 par elektrod) $2 \times 2644 = 5288$. W ten sposób utworzono 26440 wektorów zawierających 9 cech, które będą stanowiły dane wejściowe.

5.3. Implementacja metody klasyfikacji

5.3.1. Wybór metody klasyfikacji

W niniejszej pracy skorzystano z jednokierunkowej sieci neuronowej typu *patternnet* w charakterze klasyfikatora poszczególnych faz snu: W, NREM1, NREM2, NREM3, NREM4 oraz

REM. Metoda ta została wybrana ze względu na jej efektywność oraz łatwość implementacji. Procedura została wykonana w dodatku *Neural Network Toolbox* dla programu *Matlab*.

Macierz 26440 9-elementowych wektorów zawierających równy udział każdej z 5 klas została podzielona w sposób losowy na zbiór uczący (70% danych), testujący (15% danych) oraz walidacyjny (15% danych).

```
% Podział danych
net.divideFcn = 'dividerand'; % Podział losowy
net.divideParam.trainRatio = 70/100; % Zbiór uczący
net.divideParam.valRatio = 15/100; % Zbiór walidacyjny
net.divideParam.testRatio = 15/100; % Zbiór testujący
```

Na wyjście podano 5-elementowe wektory faz snu (złożone z liczby 1 przyporządkowanej do określonej fazy snu i zerami w pozostałych) odpowiadające wektorom wejściowym.

```
% Wejście i wyjście sieci neuronowej
x = [wektor_caly];
t = [fazy_cale];
```

Skorzystano z funkcji trenującej wstecznej propagacji błędów *trainscg*.

```
% Wybór funkcji trenującej
trainFcn = 'trainscg'; % Algorytm wstecznej propagacji błędów
```

Użyto sieci typu *patternnet* o 9 neuronach w warstwie wejściowej, 23 neuronach w pierwszej warstwie ukrytej, 22 neuronach w drugiej warstwie ukrytej oraz 5 neuronach w warstwie wyjściowej [40]. Algorytm ten stanowi punkt wyjścia do dalszej analizy.

```
% Architektura sieci
hiddenLayerSize = 22;
hiddenLayerSize2 = 23;
net = patternnet([hiddenLayerSize hiddenLayerSize2], trainFcn);
```

Maksymalna liczba epok użytych do trenowania sieci została ustawiona na 1000, a maksymalną liczbę błędnych walidacji ustawiono na 7.

```
% Maksymalna liczba epok
net.trainparam.epochs = 1000;
% Maksymalna liczba błędnych walidacji
net.trainparam.max_fail = 7;
```

Zaprojektowana sieć została wytrenowana przy pomocy funkcji *train*.


```
% Uczenie sieci
[net,tr] = train(net,x,t);
```

5.3.2. Wybór optymalnej struktury sieci neuronowej

W celu dostosowania struktury sieci neuronowej do zadania rozpoznawania faz snu posłużono się trzema zagnieżdżonymi pętlami for. Jako metodę oceny jakości sieci, wykorzystano funkcję *confusion*. Zwraca ona na wyjściu stosunek błędnie sklasyfikowanych klas. Procedura optymalizacji zakłada iteracyjne budowanie sieci dla 9-30 neuronów w każdej warstwie ukrytej. Dla każdej architektury następuje dziesięciokrotne wywołanie funkcji *train*.

```
% Warstwa pierwsza
for hiddenLayerSize=9:30
    % Warstwa druga
    for hiddenLayerSize2 = 9:30
        % 3 iteracje procesu uczenia dla każdej struktury
        for powtorki = 1:10
            % Stwórz sieć
            net = patternnet([hiddenLayerSize hiddenLayerSize2], trainFcn);
            net.trainparam.epochs = 1000;
            net.trainparam.max_fail = 7;
            net.performFcn = 'mse';
            % Inicjalizuj sieć
            init(net);
            % Trenuj sieć
            [net,tr] = train(net,x_temp,t_temp);
            % Sprawdź sieć
            y = net(x_wejscie);
            y = round(y);
            % Jeśli wartość niepoprawnie sklasyfikowanych faz
            % jest mniejsza, zapisz sieć
            if confusion(fazy_sieci,y) < confusion_temp
                save('siec_optymalna.mat', 'net', 'tr');
                confusion_temp = confusion(fazy_sieci,y);
            end
        end
    end
end
```

W wyniku przeprowadzenia optymalizacji, wybrano sieć o 22 neuronach w pierwszej oraz drugiej warstwie ukrytej, której poprawność rozpoznawania wzorców $p=69.1\%$. Strukturę zoptymalizowanej sieci przedstawia Rysunek 5.55.



Rysunek 5.55 – Optymalna struktura sieci neuronowej

5.3.3. Testy kompletnego algorytmu na danych wzorcowych


Na wejście wytrenowanej sieci podano wektory cech dla pełnego zestawu zgromadzonych danych pochodzących od różnych pacjentów, które złożyły się na macierz 198168x9. Następnie obliczono sumę błędu średniokwadratowego i kwadratów wag sieci.

```
% Test sieci
y = net(wektor_pelen);
e = gsubtract(fazy_pelne,y);
performance = perform(net,fazy_pelne,y)
tind = vec2ind(t);
yind = vec2ind(y);
percentErrors = sum(tind ~= yind)/numel(tind);
```


Minimalna wartość zastosowanej funkcji celu wyniosła 0.0637. Zastosowana sieć uzyskała poprawność rozpoznawania wzorców $p = 77,3\%$.

Confusion Matrix						
Output Class	1	2	3	4	5	
	113211 57.1%	520 0.3%	475 0.2%	206 0.1%	629 0.3%	98.4% 1.6%
	15570 7.9%	2614 1.3%	2415 1.2%	112 0.1%	2389 1.2%	11.3% 88.7%
	1012 0.5%	466 0.2%	19915 10.0%	858 0.4%	1373 0.7%	84.3% 15.7%
	1804 0.9%	177 0.1%	4675 2.4%	8320 4.2%	662 0.3%	53.2% 46.8%
	4931 2.5%	1535 0.8%	4818 2.4%	388 0.2%	9093 4.6%	43.8% 56.2%
						82.9% 17.1%
						49.2% 50.8%
						61.7% 38.3%
						84.2% 15.8%
						64.3% 35.7%
						77.3% 22.7%
						Target Class

Rysunek 5.56 - Macierz pomyłek dla danych testujących



Rysunek 5.57 - Histogram błędów sieci neuronowej



Rysunek 5.58 - Krzywa ROC

Sieć najlepiej rozpoznaje fazę wybudzenia (W) oraz sen wolnofalowy (SWS), a najgorzej fazę NREM1. Często zamiast tej fazy, sieć wskazywała fazę wybudzenia. Może mieć to związek z faktem, że jest to faza przejściowa pomiędzy snem, a czuwaniem (zasypianie). Obie fazy posiadają zbliżoną charakterystykę częstotliwościową.


5.3.4. Przygotowanie danych własnych

Program *OpenVibe* umożliwił zapis danych pozyskanych ze skonstruowanego urządzenia w formie pliku *.edf* oraz *.csv*. Aby możliwa była jego analiza w programie *Matlab*, skorzystano z narzędzia *BlockEdfRead*, które dokonało konwersji na plik *.mat* [42].

```
% Wczytaj plik .edf z danymi własnymi
[header, signalHeader, signalCell] = blockEdfLoad('1.edf');
% Wybierz kanał 1 (F7 - F8)
signal = signalCell{1};
```

Urządzenie próbuje sygnał z częstotliwością 256 Hz, natomiast dane pozyskane z bazy *PhysioNet Sleep Database* zawierały zapisy wykonane z częstotliwością 100 Hz. W celu użycia sygnału własnego do analizy przy użyciu zastosowanej sieci neuronowej konieczna była normalizacja danych oraz dostosowanie częstotliwości próbkowania.


```
% Konwersja częstotliwości próbkowania na 100 Hz
signal_resampled = resample(signal, 100, 256);
% Normalizacja
[signal_norm ps] = mapminmax(signal', -1, 1);
signal_norm = signal_norm';
```



Rysunek 5.59 – Pełen zapis snu o długości 59 minut i 22 sekund

Na podstawie wzrokowej analizy wykresu w zapisie zidentyfikowano artefakty, mogące być wynikiem ruchów ciała oraz zewnętrznych zakłóceń. Dokonano ich usunięcia z sygnału za pomocą następujących poleceń:

```
% Ręczne usunięcie artefaktów
signal_resampled(201500:204000)=[];
signal_resampled(154500:155000)=[];
signal_resampled(154500:155000)=[];
signal_resampled(133600:134400)=[];
signal_resampled(112800:113500)=[];
signal_resampled(58180:58890)=[];
signal_resampled(52840:54520)=[];
signal_resampled(50320:50790)=[];
signal_resampled(48010:48670)=[];
signal_resampled(43420:43820)=[];
signal_resampled(37760:39000)=[];
signal_resampled(32500:36500)=[];
signal_resampled(25000:29000)=[];
% Usunięcie szpilek
signal_resampled(signal_resampled>120)=[];
signal_resampled(signal_resampled<-40)=[];
```



Rysunek 5.60 – Przetworzony zapis snu

W ten sposób uzyskano wektor złożony z 330221 próbek. Ostatnim krokiem przygotowania danych jest podział na 30 sekundowe epoki. Aby wymiar macierzy był podzielny przez 3000 (każda epoka zawiera 30 sekund sygnału próbkowanego z częstotliwością 100 Hz, a więc 3000 elementów), konieczne było odrzucenie pierwszych 221 próbek.

```
% Podziel na 30 sekundowe epoki
signal_resaped = reshape(signal_norm(222:end), 3000, 110);
```

Przetworzone w ten sposób dane zostały zapisane do pliku *dane_wlasne.mat*.

```
%Zapisz dane
dane_wlasne = signal_resaped;
save('dane_wlasne.mat', 'dane_wlasne');
```

5.3.5. Testy kompletnego algorytmu na danych własnych

Ekstrakcja cech z danych własnych została wykonana zgodnie z procedurą opisaną w podrozdziale 4.2. - *Implementacja metody ekstrakcji cech*. Macierz złożona ze 110 wektorów, na które składały się współczynniki falkowe oraz ich ilorazy, została następnie podana na wejście wytrenowanej sieci. Wyniki klasyfikacji zostały następnie zaokrąglone do liczby całkowitej.

```
% Użyj sieci neuronowej na danych własnych
y = net(wektor_dane_wlasne);
y = round(y);
```

Wyniki klasyfikacji są zawarte w tabeli poniżej.

Tabela 2 - Wyniki klasyfikacji faz snu (dane własne)

Faza snu	Liczba epok	Udział w zapisie
Wybudzenie	7	6,4%
NREM1	53	48,1%
NREM2	8	7,3%
SWS	34	31%
REM	0	0%
BRAK JEDNOZNACZNEJ KLASYFIKACJI	8	7,2%
SUMA	110	100%

Brak jednoznacznej klasyfikacji oznacza, że po zaokrągleniu liczb w wektorze wyjściowym uzyskano dla każdej fazy liczbę 0. Taka sytuacja wystąpiła dla 8 epok, co stanowi 7,2% całości. Oznacza to, że dla 92,8% epok faza snu została przyporządkowana.

5.3.6. Hipnogram dokonanego zapisu snu

W celu prezentacji wyników klasyfikacji dla kolejnych epok zastosowano następujące polecenia:


```
% Pobierz wyniki klasyfikacji
fazy = y;

% Uporządkuj kolejność (fazy snu)
fazy(1,fazy(1,:)==1) = 5; %W
fazy(2,fazy(2,:)==1) = 3; % NREM1
fazy(3,fazy(3,:)==1) = 2; %NREM2
fazy(4,fazy(4,:)==1) = 1; %SWS
fazy(5,fazy(5,:)==1) = 4; % REM

% Oblicz długość danych
fazy=sum(fazy,1);
% Odrzuć dane o niejednoznacznej klasyfikacji
fazy(fazy==0)=NaN;

% Wyświetl wykres
plot(1:length(fazy),fazy, 'LineWidth',3);
% Dostosuj wymiary i legendę wykresu
title('Hipnogram');
xlabel('numer epoki')
ylabel('fazy snu')
yticks([0 1 2 3 4 5]);
yticklabels({'SWS', 'NREM2', 'NREM1', 'REM', 'WYBUDZENIE'});
```

Pozwolił on na stworzenie hipnogramu, który jest zawarty na rysunku poniżej.



Rysunek 5.61 – Hipnogram dla danych własnych

Pierwsze 7 epok zostało przyporządkowane do fazy wybudzenia. Kolejne epoki zostały przyporządkowane do fazy NREM1. Epoka nr 18 nie została jednoznacznie sklasyfikowana. Kolejne 42 epoki również zostały przyporządkowane do fazy NREM1. Po niej zidentyfikowano fazę NREM2 (wyłączając epoki 66-68 oraz 73-77). Ostatnie 32 epoki przyporządkowano do fazy snu wolnofalowego. Kolejność następujących po sobie epok jest prawidłowa dla cyklu snu. Wątpliwości budzić może jednak wysokie prawdopodobieństwo pomyłki fazy NREM1 z fazą wybudzenia. Uzyskane wyniki należałoby skonsultować ze specjalistą.

Rozdział 6: Propozycja algorytmu detekcji bezdechu

6.1. Tło algorytmu

Algorytm detekcji wydechu ma za zadanie analizę respiracji poprzez zliczanie oddechów. Ma on na celu pomoc w diagnostyce zespołu bezdechu sennego. Podczas akwizycji danych oddechowych zaobserwowano, że sygnał pochodzący z termistora przypomina przebieg sinusoidalny. Podczas wydechu w masce z termistorem NTC następuje jego ogrzanie, co zmniejsza jego rezystancję. Jest to rejestrowane jako trend malejący w sygnale oddechowym. Odwrotna sytuacja następuje podczas wdechu.

6.2. Opis algorytmu

Proponowany algorytm bazuje na analizie ekstremów lokalnych sygnału oddechowego. Minima są powiązane z momentem rozpoczęcia wdechu, natomiast maksima z momentem rozpoczęcia wydechu. Pary lokalnych minimów i maksimów oznaczają pełen cykl oddechowy. Procedura algorytmu jest następująca:

1. Pobierz epokę sygnału
2. Wyznacz lokalne minima (wdechy)
3. Wyznacz lokalne maksima (wydechy)
4. Policz średnią z liczby minimów i maksimów (oblicz liczbę cykli oddechowych)
5. Porównaj liczbę cykli z zadany prog
6. Zapisz numer epoki, w której nastąpiło przekroczenie minimalnego progu

6.3. Implementacja algorytmu

Implementacja algorytmu została wykonana w programie *Matlab*. Na początku skryptu ustawiana jest częstotliwość próbkowania sygnału (dla sygnału oddechowego z bazy PhysioNet jest to 1 Hz) oraz minimalny próg cykli oddechowych na minutę. Istnieje również możliwość modyfikowania długości pojedynczej epoki. Ma to szczególne znaczenie, ponieważ po wystąpieniu bezdechu, następuje okres hiperwentylacji rekompensujący brak oddechu [43].

```
% Ustaw częstotliwość próbkowania
fs = 1;
% Ustal minimalny próg cykli oddechowych na minutę
threshold = 15;
```

```
% Ustal długość epoki (s)
epoch_size = 8;
% Pobierz epokę
x = 1:epoch_size*fs;
```

Pobrano sygnał jest następnie dzielony na epoki.

```
% Podziel sygnał na epoki
wymiar = floor(length(nasal)/(epoch_size*fs));
odrzut = length(nasal) - wymiar*(epoch_size*fs)+1;
signal_resaped = reshape(nasal(odrzut:end), (epoch_size*fs), wymiar);

% Wyświetl wykres
plot(signal_resaped(1));
```

Następnie wyszukiwane są lokalne minima i maksima oraz ich indeksy. Na tej podstawie obliczana jest ilość wdechów i wydechów, a co za tym idzie cykli oddechowych.

```
% Znajdź lokalne maksima oraz ich indeksy
[maxima,ixmaks] = findpeaks(nasal(x));
% Znajdź lokalne minima oraz ich indeksy
[minima,ixmin] = findpeaks(-nasal(x));

% Zlicz wdechy
inhalations = length(minima);
% Zlicz wydechy
exhalations = length(maxima);

% Oblicz liczbę cykli oddechowych
breaths = mean(inhalations, exhalations);
```


Wyniki analizy poszczególnych epoki mogą być przedstawione na wykresie.

```
% Zaznacz ekstrema
figure(1)
plot(x, nasal(x))
hold on
plot(x(ixmaks), maxima, '^g', 'MarkerFaceColor','g')
hold on
plot(x(ixmin), -minima, '^r', 'MarkerFaceColor','r')
txt = ['Wdechy: ', num2str(inhalations), ' Wydechy: ',
num2str(exhalations), ' Cykle: ',num2str(breaths)];
text(x(3),720,txt);
```

Powyższy skrypt należy uruchamiać w pętli dla każdej epoki analizowanego sygnału. Jeśli liczba oddechów jest zbyt mała, jest ona zapisywana wraz z numerem epoki. Dzięki temu istnieje możliwość wzrokowej analizy danego fragmentu sygnału przez lekarza.

```
for epoch_number = 1: length(nasal_epochs(1,:))
    %...
End


% Zapisz liczbę oddechów oraz numer epoki ze zbyt małą liczbą cykli
if (breaths < threshold/epoch_size)
    apnea = [breaths, epoch_number];
end
```



Rysunek 6.62- 8- sekundowa epoka sygnału oddechowego z zaznaczonymi minimami i maksimami (dane z bazy PhysioNet)

6.4. Test algorytmu


Zaproponowany algorytm może być użyty dla zapisów pochodzących z różnych urządzeń i mających różne częstotliwości próbkowania. Został on przetestowany na danych zarejestrowanych przy pomocy skonstruowanego urządzenia. W tym celu dokonano 89-sekundowego zapisu sygnału oddechowego. Został on następnie wyekstrahowany z pliku *.edf*.



Rysunek 6.63 - Zarejestrowany sygnał oddechowy

Częstotliwość próbkowania została dostosowana do urządzenia. Z powodu występowania zakłóceń, zastosowano średnią ruchomą.

```
% % Ustaw częstotliwość próbkowania  
fs =256;  
nasal = movmean(nasal,fs)
```



Rysunek 6.64 -8- sekundowa epoka sygnału oddechowego z zaznaczonymi minimami i maksimami (dane własne)

W niniejszym rozdziale zaproponowano algorytm detekcji bezdechu sennego. Proponowane rozwiązanie powinno być sprawdzone pod kątem skuteczności działania, a także użyteczności w diagnozowaniu bezdechu sennego przez specjalistów.

Podsumowanie i wnioski

Sen od zarania dziejów fascynuje ludzkość. Jakość snu zależy od ogólnego stanu psychofizycznego organizmu. Problemy takie jak stres lub depresja mogą wpływać na jego przebieg. Jednym z groźniejszych zaburzeń snu jest bezdech senny. Jego identyfikacja jest utrudniona, ponieważ pacjent nie jest świadomy momentu występowania objawów.

Celem niniejszej pracy było stworzenie systemu do badań nad snem. W jego skład wchodzi: urządzenie do rejestracji sygnałów biomedycznych (elektroencefalograficznego oraz oddechowego), analizator sygnału EEG oraz automatyczny klasyfikator faz snu. Dodatkowo zaproponowano algorytm wykrywania cykli oddechowych, który może być pomocny w wykrywaniu zespołu bezdechu sennego.

Prototyp urządzenia powstał w technologii przewlekanej oraz przy wykorzystaniu płytki stykowej. Następnie została zaprojektowana płytka PCB w technologii montażu powierzchniowego. Urządzenie składa się z zespołu wzmacniaczy i filtrów, które umożliwiają rejestrację dwukanałowego sygnału elektroencefalograficznego przy pomocy pasywnych elektrod bezdotykowych oraz sygnału oddechowego, który pochodzi od termistora NTC umieszczonego w masce inhalatora. Rejestrowane sygnały są następnie przetwarzane na postać cyfrową przy pomocy przetwornika analogowo-cyfrowego mikrokontrolera *Atmega 16*. Częstotliwość próbkowania każdego sygnału wynosi 256 Hz. Następnie sygnał przy pomocy portu USB trafia do komputera. Dodatkowo istnieje możliwość rozbudowy urządzenia o zasilanie z baterii i zapis danych na karcie microSD. Urządzenie zostało zmontowane i uruchomione przez autora pracy.

W części analitycznej pracy pozyskano dane biomedyczne z bazy *PhysioNet EDF Sleep Database* zawierające 61 polisomnogramów. Z nich zostały wybrane dane EEG oraz oddechowe, które zostały przetworzone w środowisku *Matlab*.

Sygnał EEG, pochodzący od różnych pacjentów, został poddany dekompozycji przy pomocy dyskretnej transformaty falkowej DWT (*Daubechies 4*). Następnie dokonano klasyfikacji faz snu przy pomocy sztucznej sieci neuronowej zoptymalizowanej dla tego zadania architekturze. W rezultacie tych działań uzyskano sieć o 22 neuronach w pierwszej i drugiej warstwie ukrytej. Uzyskany algorytm został przetestowany przy użyciu pełnego zestawu zgromadzonych danych. Skuteczność rozpoznawania faz snu przy zastosowaniu wybranej metody wyniosła 77,3%. Wartość ta jest zbliżona dla uzyskanej w pracach naukowych [40][41].

Sygnal oddechowy jednego z pacjentów posłużył do stworzenia algorytmu wykrywania bezdechu sennego. Jest on oparty o analizę lokalnych minimów i maksimów, które składają się na jeden cykl oddechowy.

Skonstruowane na potrzeby tej pracy urządzenie zostało następnie wykorzystane do rzeczywistej akwizycji sygnałów biomedycznych. W okresie kilkunastu dni rejestrowano sygnał EEG autora pracy w trakcie snu. Spośród zapisów wybrano jeden, który posłużył następnie do przeprowadzenia analizy przy pomocy zoptymalizowanej sieci neuronowej. Faza snu została przyporządkowana w 92,8% przypadków. Wyniki klasyfikacji faz snu zarejestrowanego sygnału zostały następnie przedstawione przy pomocy hipnogramu. Kolejność następujących po sobie faz snu jest prawidłowa. Poprawność ich zaklasyfikowania powinna jednak zostać oceniona przez specjalistę.

Przy pomocy modułu oddechowego zarejestrowano sygnał z termistora, który został poddany analizie przy pomocy zaproponowanego algorytmu bezdechu sennego. Zarejestrowany sygnał wymagał wygładzenia, ale rezultaty okazały się podobne do tych uzyskanych przy pomocy zapisu z bazy *PhysioNet*. Praktyczna użyteczność systemu do wykrywania bezdechu sennego nie jest znana i powinna zostać oceniona przez lekarza.

Zrealizowany na potrzeby niniejszej pracy system składający się z urządzenia oraz algorytmów może służyć do analizowania struktury snu. Może on być dostępny dla osób, które są zainteresowane badaniami nad snem, ale nie mają dostępu do profesjonalnego badania polisomnograficznego. Jego praktyczna użyteczność w diagnozowaniu zaburzeń powinna jednak zostać dokładniej zbadana i skonsultowana ze specjalistami z zakresu medycyny.

Bibliografia

- [1] M. M. Billiard. *Sleep disorders in adults. Sleep disorders in adults; biological mechanisms through which sleep disorders affect the health of adults. Identification of environmental factors leading to clinical sleep disorders*, w: *WHO technical meeting on sleep and health*, Bonn: World Health Organization 2004
- [2] P. Kiciński, M. Zakrzewski, A. Dybała, R. Zubilewicz, J. Mosiewicz, A. Jaroszyński, *Obturacyjny bezdech senny — zasady diagnostyki i leczenia*, Forum Medycyny Rodzinnej 2012, tom 6, nr 5, 228–235
- [3] E. Hopps, G. Caimi, *Obstructive Sleep Apnea Syndrome: Links Between Pathophysiology and Cardiovascular Complications*, Clin Invest Med • Vol 38, nr 6, grudzień 2015
- [4] Ge X, Han F, Huang Y, Zhang Y, Yang T, Bai C, Guo X. *Is obstructive sleep apnea associated with cardiovascular and all-cause mortality?*, PlosOne 2013; 8: e69432
- [5] <http://advancemedical.cl/imagenes/estudios-de-sueno-11.jpg>
- [6] A. Ciechan, *Zastosowanie badań elektroencefalograficznych w diagnostyce chorób układu nerwowego*, Neurokognitywistyka w patologii i zdrowiu, Pomorski Uniwersytet Medyczny w Szczecinie (2009–2011) s. 43–54
- [7] *The international 10-20 system seen from (A) left and (B) above the head.* <http://www.bem.fi/book/13/13x/1302ax.htm> [dostęp: 20.02.2018]
- [8] B. A. Phillips, R. L. Gelula, *Sleep-Wake Cycle: Its Physiology and Impact on Health*, National Sleep Foundation, 2006, <https://sleepfoundation.org/sites/default/files/SleepWakeCycle.pdf> [dostęp 28.03.2018]
- [9] *Hypnogram*, <http://doctorstevenpark.com/why-do-i-always-wake-up-after-5-hours-of-sleep/hypnogram-2> [dostęp: 21.02.2018]
- [10] http://samples.jbpub.com/9781284030273/Chapter1_Secure.pdf [dostęp: 02.04.2018]
- [11] R. E. Brown, R. Basheer, J. T. McKenna, R. E. Strecker, R. W. McCarley, *Control of sleep and wakefulness*, Physiol Rev. 2012 Jul; 92(3): 1087–1187
- [12] Farah Q Al-Khalidi, Reza Saatchi, Derek Burke, Heather E Elphick, Stephen Tan, *Respiration Rate Monitoring Methods: A Review*, Pediatric Pulmonology, Wiley, 2011, 46 (6), pp.523
- [13] Richard B. Berry, *Monitoring Respiration—Technology and Techniques*, Fundamentals of Sleep Medicine, 2012
- [14] Emil Jovanov, Dejan Raskovic, Rick Hormigo, *Thermistor-based Breathing Sensor for Circadian Rhythm Evaluation*, Biomed Sci Instrum. 2001;37:493–7.
- [15] P. Augustyniak, *Transformacje falkowe w zastosowaniach elektrodiagnostycznych*, Uczelniane wydawnictwa naukowo-techniczne, Kraków 2003, s.36
- [16] Noor Kamal Al-Qazzaz, Sawal Hamid Bin Mohd Ali, Siti Anom Ahmad, Mohd Shabiul Islam, Javier Escudero, *Selection of Mother Wavelet Functions for Multi-Channel EEG Signal Analysis during a Working Memory Task*, Sensors (Basel). 2015 Nov; 15(11): 29015–29035.
- [17] Mansur Mohamed Ali, Khalifa Nusrat, Abdelhafid Ali I. Mohamed, Mohamed Ali Hagal, Hend Hadia Ali Almezogi, Javad Rahebi, Aybaba Hançerlioğullari, *Finger Vein Recognition with Gray Level Co-Occurrence Matrix based on Discrete Wavelet Transform*, International Journal of Computer Science and Technology, vol. 8, issue2, April – June 2017
- [18] Abbasi O, Rostami A, Karimian G, *Identification of exonic regions in DNA sequences using cross-correlation and noise suppression by discrete wavelet transform*. BMC Bioinformatics (2011)
- [19] Osowski S., *Sieci neuronowe do przetwarzania informacji*, Oficyna Wydawnicza Politechniki Warszawskiej, Warszawa 2006.

-
- [20] <https://towardsdatascience.com/machine-learning-fundamentals-ii-neural-networks-f1e7b2cb3eef> [dostęp: 21.05.2018]
- [21] Osowski S., *Sieci Neuronowe w ujęciu algorytmicznym*, Wydawnictwo Naukowo-Techniczne, Warszawa 1996.
- [22] G. H. Klem, H. O. Lüders, H.H. Jasper, C. Elger, *The ten-twenty electrode system of the International Federation*, *Electroencephalography and Clinical Neurophysiology Supplement* 1999;52:3-6.
- [23] <http://openeeg.sourceforge.net/doc/index.html> [dostęp: 04.03.2018]
- [24] Jaakko Malmivuo, Robert Plonsey, *Bioelectromagnetism. 13. Electroencephalography*, w: *Bioelectromagnetism - Principles and Applications of Bioelectric and Biomagnetic Fields*, Oxford University Press, 1995
- [25] <http://openvibe.inria.fr/> [dostęp: 15.04.2018]
- [26] <http://openeeg.sourceforge.net/doc/> [dostęp: 15.04.2018]
- [27] Analog Devices, Inc., “AD620 datasheet, rev. H.” http://www.analog.com/static/imported-files/data_sheets/AD620.pdf [dostęp: 10.03.2018]
- [28] M. R. Neuman, *Biopotential Amplifiers, Medical Instrumentation: Application and Design* (J. G. Webster, ed.), Nowy Jork, John Wiley & Sons, 2009.
- [29] <https://extronic.pl/content/11-wzmacniacz-instrumentalny> [dostęp: 11.03.2018]
- [30] Burr-Brown, „INA114 datasheet” <https://www.ti.com/lit/ds/symlink/ina114.pdf> [dostęp: 11.03.2018]
- [31] A. C. Metting Van Rijn, A. Peper, C. A. Grimbergen, *Instrumentation Amplifiers for bioelectric events: a design with a minimal number of parts*, ACMVRCA Grimbergen, 1994
- [32] Maneesh Gupta, Hana Qudsi, *Thermistor Respiratory Monitor. A low-cost, easy-to-use device to monitor the breathing of patients* http://people.ece.cornell.edu/land/courses/ece4760/FinalProjects/f2012/htq2_mg573/htq2_mg573/index.htm [dostęp 12.06.2018]
- [33] Diodes Incorporated, *AP431/AP431A datasheet*, https://pl.mouser.com/datasheet/2/115/AP431_A-1091776.pdf [dostęp 13.06.2018]
- [34] FTDI Chip, *FT232RL datasheet*, http://www.ftdichip.com/Support/Documents/DataSheets/ICs/DS_FT232R.pdf [dostęp 12.06.2018]
- [35] <https://www.olimex.com/Products/EEG/OpenEEG/> [dostęp 22.04.2018]
- [36] Pracki T., Pracka D., *Polisomnografia. Rozwój metod badawczych nad czynnością bioelektryczną mózgu we śnie*, *Sen* 6 (1) (2006) 30-40.
- [37] http://eegatlas-online.com/myapplications/images/MON/int10_20.png [dostęp 13.08.2018]
- [38] <https://www.physionet.org/pn4/sleep-edfx/> [dostęp 12.03.2018]
- [39] <https://www.teuniz.net/edfbrowser/> [dostęp 12.06.2018]
- [40] M. Prucnal, A. G. Polak, *Effect of feature extraction on automatic sleep stage classification by artificial neural network*, *Metrology and measurement systems*, Vol. 24 (2017), No. 2, pp. 229–240
- [41] Lung Chuin Cheong, Rubita Sudirman, Siti Suraya Hussin, *Feature extraction of EEG signal using wavelet transform for autism classification*, *ARPN Journal of Engineering and Applied Sciences*, vol. 10, no 19, Asian Research Publishing Network (ARPN), October 2015
- [42] <https://www.mathworks.com/matlabcentral/fileexchange/42784-blockedfload> [dostęp 12.04.2018]
- [43] J. Zieliński, *Mechanizmy i patofizjologia obturacyjnego bezdechu podczas snu*, *Pneumonologia i Alergologia Polska* 2007, 75, supl. 1, strony 9–1414